Fundação Getúlio Vargas
Escola de Matemática Aplicada

Luciano Guimarães Monteiro de Castro

Análise dos Microdados do ENEM a partir da Teoria da Resposta ao Item

Rio de Janeiro
2017

Luciano Guimarães Monteiro de Castro

Análise dos Microdados do ENEM a partir da Teoria da Resposta ao Item

Dissertação submetida à Escola de Matemática Aplicada como requisito parcial para a obtenção do grau de Mestre em Modelagem Matemática da Informação.

Orientador: Paulo Cezar Pinto de Carvalho

Rio de Janeiro
2017

Ficha catalográfica elaborada pela Biblioteca Mario Henrique Simonsen/FGV

Castro, Luciano Guimarães Monteiro de
Análise dos microdados do ENEM a partir da teoria da resposta ao item / Luciano Guimarães Monteiro de Castro. – 2017.
58 f.

Dissertação (mestrado) – Fundação Getulio Vargas, Escola de Matemática Aplicada.
Orientador: Paulo Cezar Pinto de Carvalho.
Inclui bibliografia.

1. Estatística matemática. 2. Teoria da resposta do item. 3. Exame Nacional do Ensino Médio (Brasil). I. Cesar, Paulo, 1952- . II. Fundação Getulio Vargas. Escola de Matemática Aplicada. III. Título.

CDD – 519.5

FGV

LUCIANO GUIMARÃES MONTEIRO DE CASTRO

ANÁLISE DOS MICRO-DADOS DO ENEM A PARTIR DA TEORIA DA RESPOSTA AO ITEM.

Dissertação apresentada ao Curso de Mestrado em Modelagem Matemática da Informação da Escola de Matemática Aplicada da Fundação Getulio Vargas para obtenção do grau de Mestre em Modelagem Matemática da Informação.

Data da defesa: 09/05/2017.

ASSINATURA DOS MEMBROS DA BANCA EXAMINADORA

Paulo Cezar Pinto Carvalho
Orientador (a)

Moacyr Alvim Horta Barbosa da Silva

Ruben Klein

Agradecimentos

Agradeço a Sorandra, minha esposa, e a nossos filhos Alicia, Elisa e Miguel, pela paciência e apoio durante a realização deste trabalho. Por entenderem, cada um do seu jeito, os momentos em que minha atenção estava exageradamente focada em códigos e números estranhos exibidos na tela do computador. E por me proporcionarem a base emocional fundamental para tudo o que realizo.

Ao meu orientador Paulo Cezar agradeço primeiramente por me ajudar a vencer o ceticismo inicial em relação à TRI, anos antes de surgir a ideia deste trabalho. Depois por me incentivar a iniciar os estudos sobre o tema, formal e informalmente, e por toda a paciência e orientação ao longo de todo o processo. Há muito tempo me impressiona a densidade de sabedoria e relevância em suas palavras.

Ao meu amigo (e ex-aluno) Fábio Dias Moreira, agradeço por inúmeras conversas produtivas sobre a TRI, e pelas correções e sugestões ao primeiro manuscrito.

Aos meus colegas da Escola de Matemática Aplicada da FGV, tenho muito a agradecer. Maria Izabel Camacho, pelo olhar sempre generoso e interessado, e por me incentivar a melhorar sempre. Moacyr Alvim, por ter acompanhado diretamente a elaboração deste trabalho com grande interesse e excelentes comentários e observações, sempre com grande disposição para ouvir, entender e orientar. Asla Sá, por ajudar a mudar minha compreensão sobre visualização de dados, influenciando decisivamente o resultado deste trabalho. Alexandre Rademaker, pelo excelente curso de Estrutura de Dados no qual baseei a mairoria dos códigos e algoritmos aqui utilizados. Renato Souza e Flávio Coelho, com quem aprendi a usar o Phython com rapidez e eficiência. Marcio Watanabe, pelo incentivador interesse no tema, por levantar excelentes perguntas e por ler o primeiro manuscrito com diligência e atenção, apontando-me correções e melhorias. Eduardo Wagner, Antônio Carlos Branco, Hugo de La Cruz, Walter Sande, pela amizade e incentivo. Elisângela Souza e Cirlei Oliveira, pelo inestimável apoio administrativo. Em geral, agradeço a todos que ajudam a criar na EMAp um ambiente leve e frutífero.

Ao Professor Ruben Klein, agradeço por ter aceitado fazer parte da banca e pelas valiosas correções, observações e sugestões.

Agradeço também aos meus colegas professores, coordenadores e diretores do Sistema ELITE de Ensino com quem troquei ideias, a partir de 2009, sobre a "novidade" da TRI no ENEM. As dúvidas então surgidas foram o principal combustível para a realização do presente trabalho. Entre eles, agradeço especialmente a Flávio Rocha e Rogério Gonçalves.

Finalmente, agradeço às pessoas que contribuíram com a minha formação acadêmica, profissional e pessoal: meus pais, Antônio Carlos e Nilce, pela base ética e moral, minhas irmãs Ana Paula e Simone pelo companheirismo; meus professores, especialmente os que me incentivaram a superar limites ("Dona" Helena, Marcelo Xavier, José Francisco, José Ricardo, Cláudio Brandão, Ubirajara Borges, Ralph Teixeira, Antônio Carlos, Nicolau Saldanha, Carlos Frederico Palmeira, Carlos Tomei, Sueli Druck, Félix Delgado, Juan Tena, Felipe Cano, José Manuel Aroca, Tomás Sanchez Giralda, Mark Spivakovsky, entre outros); e meus alunos, cuja curiosidade e interesse me impulsionam a melhorar sempre.

Resumo

A partir de 2009 o Exame Nacional do Ensino Médio (ENEM) passou a utilizar a Teoria da Resposta ao Item (TRI) para o cálculo das notas dos candidatos.

Os microdados do ENEM divulgados pelo INEP (Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira) contêm informação detalhada sobre todas as aplicações do exame. No entanto, além das próprias notas, não há dados diretamente ligados à implementação da TRI.

No presente trabalho analisamos os microdados do ENEM sob o ponto de vista do modelo logístico de três parâmetros da TRI, com dois principais objetivos: 1) Gerar mais informações sobre a implementação da TRI no ENEM, em particular estimando os parâmetros utilizados em cada questão da prova; 2) Tratar a informação obtida e propor diferentes formas de apresentá-la de maneira a melhorar a compreensão sobre os efeitos da utilização da TRI sobre as notas do exame.

Os métodos de estimação dos parâmetros das questões podem ser utilizados, por exemplo, para criar exames simulados cujas notas sejam calculadas na mesma escala utilizada pelo ENEM, e com a mesma metodologia, permitindo uma melhor avaliação dos candidatos durante sua preparação para o exame.

Abstract

Since 2009 the Brazilian National High School Examination (Exame Nacional do Ensino Médio - ENEM) started utilising the Item-Response Theory (IRT) to determine students scores. Since 2009 the Brazilian National High School Examination (Exame Nacional do Ensino Médio - ENEM) started utilising the Item-Response Theory (IRT) to determine students scores.

The ENEM micro data published by INEP (Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira) contains detailed information about all instalments of the examination. But there is no data directly related to the actual IRT implementation besides the scores themselves.

In this work we analyse the ENEM micro data under the the light of the three parameter logistic model of IRT, with two main goals: 1) To generate more information on the implementation of IRT used in ENEM, particularly estimating the parameters used for each question of the examination; 2) Treat the information gathered and suggest different ways of presenting it in order to improve the understanding of the effect of utilising IRT over the examination scores.

The item estimation methods may be used, as an example, to create simulated examinations and calculate the scores on the same scale used by ENEM, with the same methodology, allowing for a better assessment of students preparing for the examination.

ANÁLISE DOS MICRODADOS DO ENEM A PARTIR DA TRI

LUCIANO GUIMARÃES MONTEIRO DE CASTRO

Conteúdo

1. TRI 8
1.1. Modelos Logísticos 9
1.2. Modelo Logístico de Um Parâmetro (ML1) 10
1.3. Modelo Logístico de Dois Parâmetros (ML2) 11
1.4. Modelo Logístico de Três Parâmetros (ML3) 13
2. Desafios Computacionais 14
2.1. Estimação da habilidade conhecidos os parâmetros dos itens 15
2.2. Estimação dos parâmetros do item conhecidas as habilidades 18
2.3. Estimação conjunta de parâmetros dos itens e habilidades 19
3. TRI no Enem 20
3.1. Escala de proficiência (habilidade) 20
3.2. Pretestes 21
4. Acessando os microdados do Enem 21
5. Primeiras Análises 22
5.1. Verificação de coerência 22
5.2. Contribuição de cada questão para a nota do candidato 23
5.3. Funções probabilidade por proficiência para cada questão 24
6. Estimação dos parâmetros de cada questão 26
6.1. Funções probabilidade de cada questão 27
6.2. Utilização de pacotes de implementação do ML3 36
6.3. Comparação dos Resultados 41
7. Simulações 45
7.1. Estimação dos parâmetros 46
8. Conclusões 54
9. Próximos Passos 56
9.1. Otimização da função global dos parâmetros 56
9.2. Estimação conjunta e métodos Bayesianos 56

9.3. Simulados 56
9.4. Mais informação sobre o ML3 utilizado no ENEM 56
Referências 57

1. TRI

A *Teoria da Resposta ao Item*, TRI, é um paradigma para avaliações baseadas em testes. Tais avaliações são essenciais para a tomada de decisões em diversos contextos, exigindo qualidade e confiabilidade da informação obtida a partir dos resultados dos testes.

A TRI se propõe a resolver uma série de dificuldades teóricas e práticas da Teoria Clássica dos Testes, em particular a comparação de resultados de testes diferentes aplicados a grupos diferentes.

Entre as principais limitações da teoria clássica, destaca-se a impossibilidade de se separar as características dos examinados das características do teste. Assim, se o teste mede uma determinada habilidade, tal habilidade é definida em função da performance no próprio teste. Ao ser submetido a um teste mais difícil, um mesmo examinado aparentará ter menos habilidade. Por outro lado, a dificuldade de um teste é medida pela performance geral dos examinados, ou seja, ela também depende implicitamente da habilidade dos examinados.

Assim, é muito difícil comparar indivíduos submetidos a testes diferentes, assim como é difícil comparar itens cujas características são obtidas usando grupos diferentes de examinados.

A proposta da TRI para resolver este problema (e alguns outros) é partir de um modelo teórico baseado nos itens e não nos testes. Considera-se que a probabilidade de um indivíduo dar uma determinada resposta a um determinado item depende apenas de certas características intrínsicas do indivíduo, chamadas *traços latentes*, e do próprio item, e não dos outros itens do teste, ou da ordem em que os itens são apresentados.

Assim, cada resposta obtida representa uma "pista" sobre os valores dos traços latentes que o teste pretende avaliar, e o resultado de um teste é um conjunto de tais pistas, utilizado para obter valores concretos que quantifiquem os traços latente em determinada escala.

Neste texto nos limitaremos a modelos com um único traço latente e itens dicotômicos, ou seja, itens que admitem apenas duas respostas possíveis (certo ou errado, por exemplo). Informações sobre modelos politômicos e com mais de um traço latente podem ser encontradas em [3] ou [6].

Assim, nossa primeira hipótese é de que os indivíduos examinados possuem um traço latente que pode ser quantificado por um número real z em determinada escala, e a probabilidade de um examinado acertar ou errar um determinado item

depende apenas de z e do item. A segunda hipótese é a da independência condicional dos itens, ou seja, a probabilidade de um examinado acertar ou errar qualquer item não depende dos outros itens do teste, mas apenas do traço latente z (mesmo esta segunda hipótese sendo uma consequência da primeira, é usual e importante enfatizá-la).

1.1. **Modelos Logísticos.** O próximo passo na construção do modelo é definir as funções de probabilidade para cada item, em função do traço latente z e de parâmetros relativos ao próprio item. Atualmente as mais utilizadas são as funções do tipo *logístico*, que dão origem aos chamados *modelos logísticos*.

Tais modelos surgiram a partir das dificuldades práticas de se trabalhar com escalas de valores limitados, como por exemplo valores de probabilidades, restritos ao intervalo $[0, 1]$. Trocando o valor p da probabilidade por $\frac{p}{1-p}$, razão normalmente conhecida como *chance* (do inglês *odds*), amplia-se o intervalo de valores possíveis para $[0, \infty]$. Finalmente, tomando o logaritmo da chance obtemos toda a reta real como conjunto de valores possíveis.

A principal vantagem desta mudança de variáveis é faciltar a utilização de aproximações lineares para a dependência entre diferentes variáveis. Para diversas aplicações práticas, esse tipo de aproximação é suficiente.

Em nosso caso, se houver uma boa aproximação linear para a dependência entre $\log\left(\frac{p}{1-p}\right)$ e z, sendo p a probabilidade de um examinado acertar o item e z o valor do traço latente, teremos

$$z = \alpha \cdot \log\left(\frac{p}{1-p}\right) + \beta,$$

para certos parâmetros reais α e β.

Resolvendo a equação para p obtemos

$$p = \frac{1}{1 + \exp\left(-\frac{1}{\alpha}(z - \beta)\right)}. \tag{1.1}$$

Esta equação é a base para os três modelos logísticos mais utilizados, os de um, dois ou três parâmetros. O gráfico de p em função de z tem o aspecto de um "s" alongado, com assíntotas horizontais correspondentes às probabilidades 0 e 1.

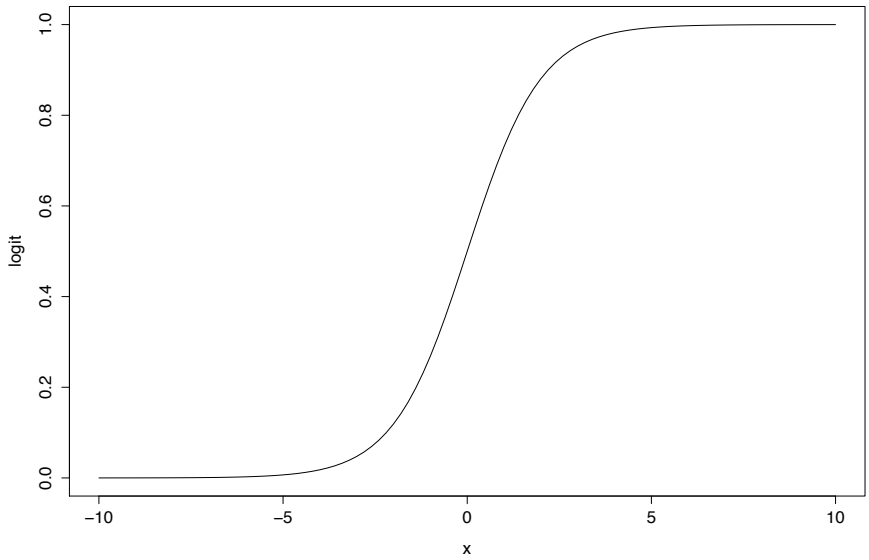

1.2. **Modelo Logístico de Um Parâmetro (ML1).** Com uma simples mudança na escala de medida de z, a equação 1.1 pode assumir o formato simplificado $p = \dfrac{1}{1+\exp(-(z-b))}$. Esta expressão é a base para o modelo logístico de um parâmetro. Precisamos fazer a hipótese adicional de que exista uma única mudança de escala para qual as funções probabilidade de *todos* os itens utilizados assuma esse formato simplificado. Em outras palavras, numeramos os itens e consideramos que a função $p_i : \mathbb{R} \to [0,1]$ que associa a cada valor z do traço latente a probabilidade $p_i(z)$ de que um examinado com este valor de traço latente responda corretamente ao item número i assume a forma

$$p_i(z) = \frac{1}{1+\exp(-(z-b_i))}. \tag{1.2}$$

Assim, a cada item i está associado um único parâmetro real b_i, e tal parâmetro determina a função probabilidade associada ao item, também conhecida como *curva característica* do item.

Este parâmetro b_i (ao que nos referiremos simplesmente como *parâmetro* b quando não estivermos nos referindo a um item específico) costuma ser chamado de *parâmetro de dificuldade*. De fato, um examinado com traço latente igual a b_i tem probabilidade 0.5 de responder corretamente ao item i, e como a função

probabilidade é crescente, quanto maior o valor de b_i, menor será o número de examinados com chance maior ou igual a 0.5 de responder corretamente o item i.

Os gráficos das diferentes funções probabilidades serão translações horizontais uns dos outros sendo $(b_i, 0.5)$ o ponto de inflexão do gráfico correspondente ao item i. A figura a seguir mostra alguns gráficos deste tipo.

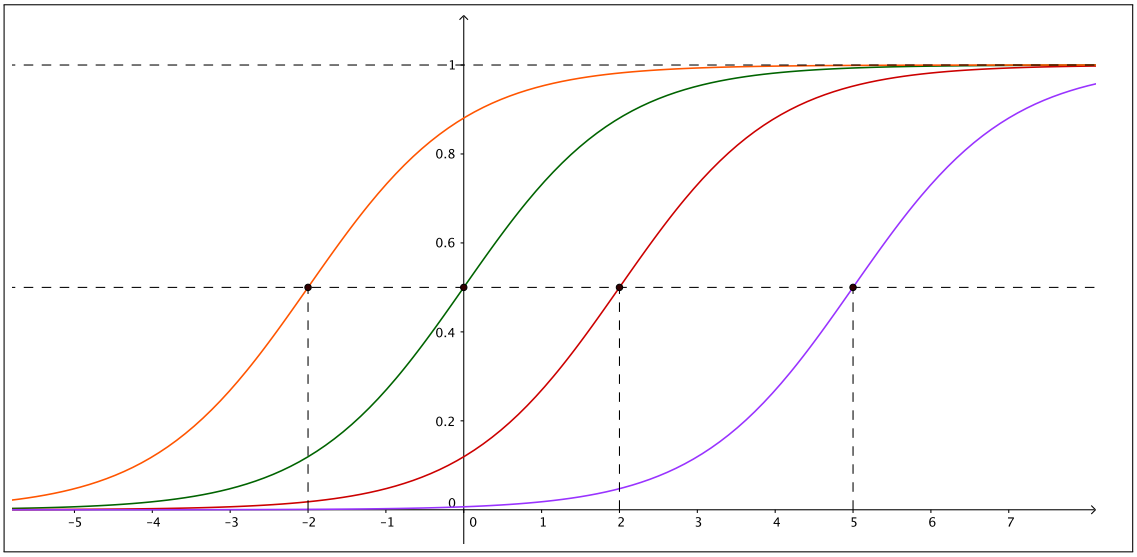

A principal restrição para a aplicação prática deste modelo é a rigidez das hipóteses sobre o comportamento dos itens. Para sua correta utilização pode ser necessária a eliminação de itens pouco compatíveis. Mesmo assim, é um modelo amplamente utilizado na prática [6].

A grande vantagem é simplificar os métodos numéricos de otimização necessários, reduzindo o tempo e aumentando a qualidade dos resultados computacionais. Em alguns casos, pode-se utilizar o modelo de dois parâmetros para selecionar um subconjunto de itens para os quais o ML1 seja adequado, como veremos a seguir.

1.3. **Modelo Logístico de Dois Parâmetros (ML2).** Este é o modelo obtido utilizando-se diretamente a equação 1.1 para descrever as curvas características dos itens. Para cada item i, a função p_i fica determinada por dois parâmetros reais a_i e b_i e assume a forma

$$p_i(z) = \frac{1}{1 + \exp\left(-a_i(z - b_i)\right)} \tag{1.3}$$

Novamente o parâmetro b_i é conhecido como parâmetro de dificuldade, e a_i é chamado *parâmetro de discriminação*. Aqui, discriminação significa a capacidade de o item distinguir examinados de habilidades ligeiramente diferentes, e depende não só das características do item, mas também do valor do traço latente.

Por exemplo, se considerarmos dois indivíduos com habilidades próximas e muito maiores (ou menores) do que b_i, a curva característica entre abscissas correspondentes é praticamente horizontal, portanto ambos os indivíduos têm probabilidades de acerto quase iguais e o item pouco serve para diferenciá-los. Contrariamente, se temos um indivíduo com habilidade um pouco menor que b_i e outro com habilidade um pouco maior que b_i, as probabilidades de acerto serão significativamente diferentes.

Em outras palavras, a discriminação do item i ao redor de um certo valor z do traço latente é proporcional à inclinação da curva característica de i em z. Tal inclinação é máxima para $z = b_i$, e esse máximo é proporcional ao valor de a_i, daí o nome escolhido.

A possibilidade de itens com discriminações diferentes acrescenta riqueza e flexibilidade ao modelo. Um item com parâmetro a muito grande discrimina excelentemente examinados com habilidades em um pequeno intervalo ao redor de b. Já um item com parâmetro a pequeno discrimina, menos intensamente, indivíduos com habilidades em um intervalo bem maior.

A figura a seguir representa algumas curvas características de itens do ML2. Mantém-se o formato de "S", sendo alguns mais alongados que outros. Não há o paralelismo observado no ML1, de forma que um item com b maior do que outro, mas com menor valor de a pode ser mais fácil para candidatos com habilidade pequena o suficiente, e vice-versa caso o valor de a seja também maior.

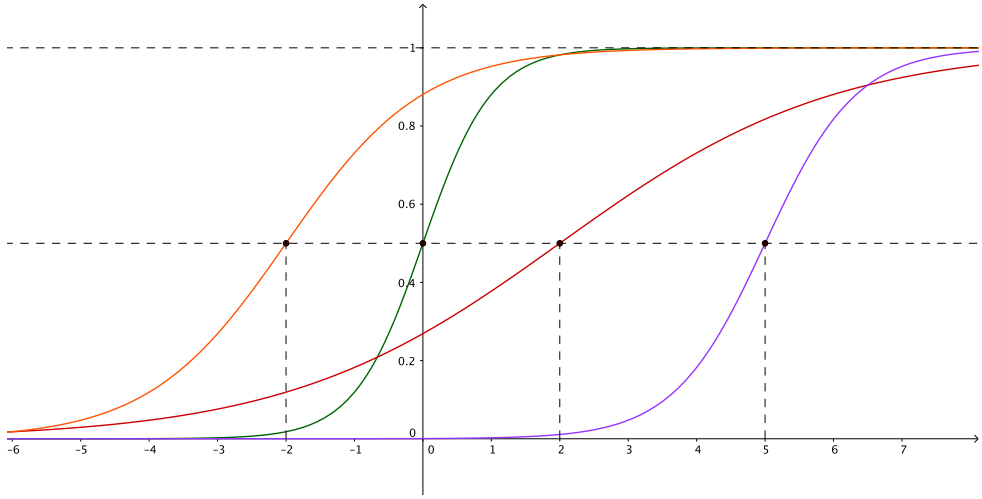

Após a criação de um banco de itens seguindo o ML2, é possível selecionar um subconjunto para o qual todos os itens têm valores similares de a, e então utilizá-los para a criação de testes no modelo ML1, obtendo vantagens computacionais.

1.4. **Modelo Logístico de Três Parâmetros (ML3).** As curvas características dos itens no ML1 e ML2 possuem, todas, uma assíntota horizontal em $p = 0$. Isto significa que indivíduos com habilidade muito baixa têm probabilidade praticamente nula de responder corretamente o item. Mas isto não é verdade para itens que admitam acerto casual, como é o caso das questões de múltipla escolha amplamente utilizadas em exames como vestibulares e o ENEM, objeto principal de nosso estudo.

A solução proposta pelo ML3 é simplesmente mudar a assíntota inferior da curva característica do item i para uma reta $p = c_i$, com c_i um número entre 0 e 1 que representa a probabilidade de indivíduos de habilidade muito baixa responderem corretamente o item. Fora esta mudança de assíntota, supõe-se um formato similar ao do ML2 para a curva. Assim, obtemos a seguinte expressão para a função p_i:

$$p_i = c_i + \frac{1 - c_i}{1 + \exp\left(-a_i(z - b_i)\right)} \tag{1.4}$$

Apesar da aparência simples desta modificação em relação ao ML2, as consequências são significativas. A principal perda é computacional. Como esta equação já não tem o formato de 1.1, já não há a possibilidade recorrer a métodos de regressão linear em qualquer etapa do processo de estimação dos parâmetros.

Assim, os métodos computacionais conhecidos para implementação do ML3 são lentos e instáveis, com diversos problemas de convergência, sendo o parâmetro c usualmente o mais problemático ("The three parameter model is known to have numerical problems like non-convergence or convergence on the boundary, especially for the guessing parameters" [10], p. 62). Mais adiante teremos oportunidade de observar este problema na prática, quando apresentarmos nossos resultados para as estimativas dos parâmetros das questões do ENEM. Veremos que o valor do parâmetro c é o que apresenta as maiores distorções entre diferentes métodos.

A figura a seguir mostra algumas curvas características de itens no ML3. O formato de "S" permanece, mas com diferentes "bases" devido à variação da assíntota inferior. O valor de b continua sendo a abscissa do ponto de inflexão da curva, mas a ordenada passa a ser $\frac{1+c}{2}$, que também varia com o item.

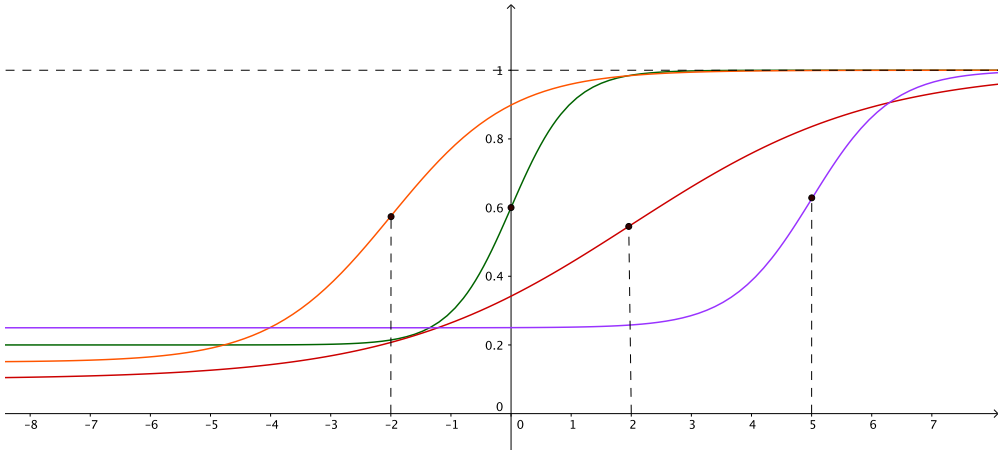

2. Desafios Computacionais

Apesar de os fundamentos teóricos da TRI terem surgido por volta de 1950, apenas na década de 1980 surgiram os primeiros pacotes computacionais que tornariam viável sua implementação. Os desafios de otimização e estimação envolvidos são consideráveis, e diversas soluções foram propostas e testadas desde então.

O problema é complexo porque nem o traço latente e nem os parâmetros dos itens são variáveis observáveis. Tudo o que podemos observar são as respostas de um certo grupo de indivíduos aos itens.

Em sistemas de avaliação já consolidados como o TOEFL ou o SAT há um grande banco de dados de itens cujos parâmetros já são conhecidos, e pode-se estimar o traço latente de um examinado a partir dessa informação. Reciprocamente,

se já estimamos a habilidade de um grupo grande de pessoas às quais submetemos um novo item, os parâmetros desse item podem ser estimados.

Assim, o mais comum é mesclar em um mesmo teste itens com parâmetros já conhecidos com novos itens cujos parâmetros serão determinados a posteriori, de forma a obter uma estimação confiável para as habilidades dos examinados e ao mesmo tempo aumentar o banco de itens com parâmetros conhecidos, mantendo sempre a mesma escala para medir o traço latente z.

Qualquer sistema de avaliação que utilize a TRI deve, contudo, partir de um ponto em que nenhum parâmetro é conhecido e os únicos dados disponíveis são as respostas de um certo grupo de examinados a um certo conjunto de itens. Isto gera um complexo problema de otimização envolvendo um grande número de parâmetros.

Consideraremos brevemente cada uma dessas situações. Mais detalhes podem ser encontrados em [1], [6] ou [3].

2.1. **Estimação da habilidade conhecidos os parâmetros dos itens.** Este é o problema de otimização mais simples nas aplicações da TRI, basicamente por envolver a otimização de uma função de um único parâmetro. Supomos a aplicação de um teste com n itens de parâmetros conhecidos a um grupo de N indivíduos.

Conhecidos os parâmetros dos itens, as funções probabilidade p_i são conhecidas, assim como é conhecida a resposta R_{ij} dada pelo candidato número j ao item número i. Adotamos a convenção $R_{ij} = 1$ se a resposta é correta, e $R_{ij} = 0$ caso contrário. O vetor $(R_{ij})_{i=1}^{n}$ é chamado de *padrão de respostas* do candidato número j.

Assim, utilizando a hipótese de independência condicional entre os itens, podemos calcular a probabilidade $P_j(z)$ de um indivíduo de habilidade z apresentar o mesmo padrão de respostas do candidato j:

$$P_j(z) = \prod_{i=1}^{n} R_{ij} p_i(z) \cdot (1 - R_{ij})(1 - p_i(z)).$$

Adotamos como estimativa para a habilidade do candidato j o valor z_j que maximiza a probabilidade P_j. Este é o método conhecido como de *máxima verosimilhança.*

Na prática, é usual substituir a função P_j por $\log(P_j)$ para realizar os cálculos da otimização. Além da conveniência de substituir um produto por uma soma, como os fatores do produto estão entre 0 e 1 os valores de P_j são muito pequenos.

Observe que o cálculo é feito separadamente para cada indivíduo, de maneira que é teoricamente possível aplicar um teste a um único indivíduo e ainda assim executar os mesmos cálculos para avaliar sua habilidade. A qualidade da avaliação depende do número de itens aplicados ao indivíduo, sendo que quanto mais itens são aplicados, maior a precisão da avaliação.

A figura a seguir mostra um exemplo de gráfico de uma função $\log(P_j)$, gerada por uma simulação de respostas de um examinado a 45 itens de uma prova estilo ENEM, no modelo ML3.

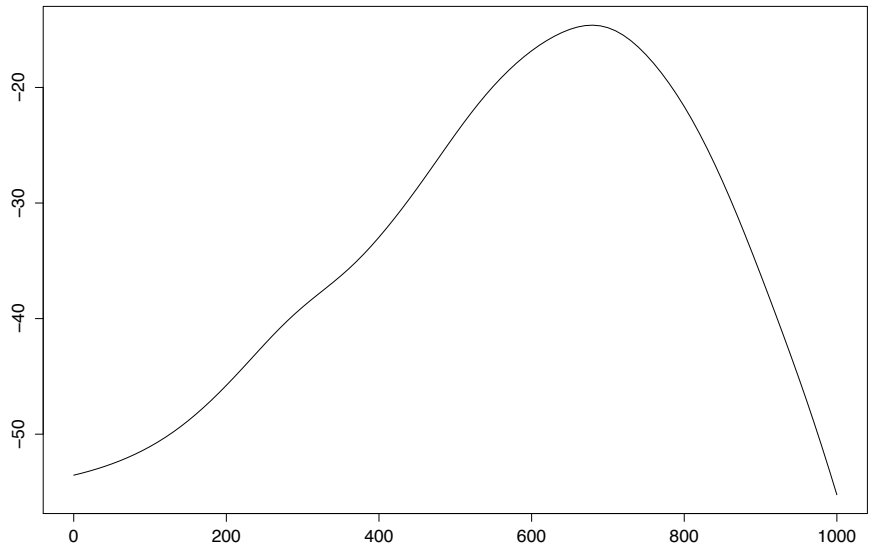

Há um máximo muito claro entre 600 e 800 na escala apresentada e podemos ter bastante segurança em afirmar que a habilidade do candidato está bem próxima desse máximo (aproximadamente 676).

A situação é menos clara para indivíduos com baixa habilidade, como mostra o exemplo a seguir, obtido com o mesmo tipo de simulação:

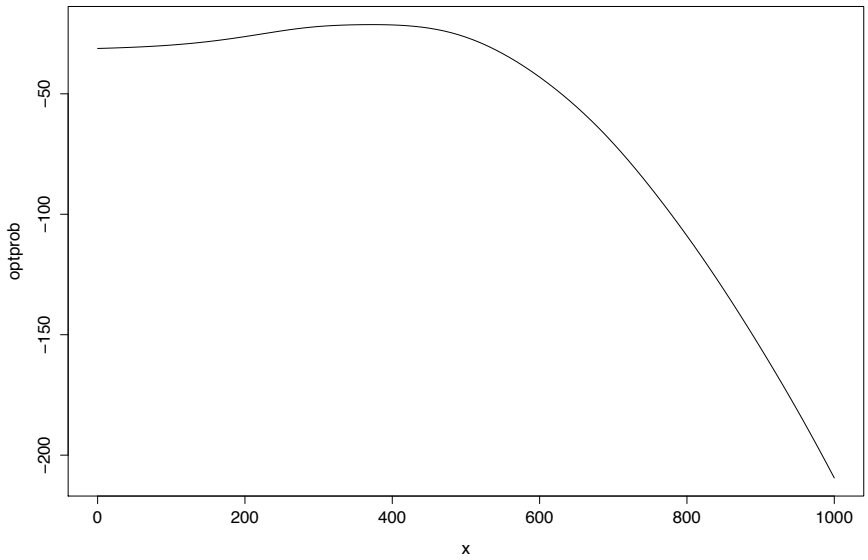

Observando o gráfico é razoável imaginar que a habilidade do candidato está entre 300 e 500, mas visualmente quase qualquer valor neste intervalo tem verosimilhança parecida. O máximo é obtido para habilidade aproximadamente 372.

A dificuldade observada neste último exemplo acentua-se nos casos em que há poucas respostas corretas, sendo crítico quando todas as respostas são incorretas e também quando todas são corretas. Nestes dois casos o método da máxima verosimilhança não é capaz de estimar a habilidade.

Estas dificuldades podem ser resolvidas adotando o método conhecido como *estimação bayesiana*, baseado no *Teorema de Bayes* que pode ser resumido pela equação

$$p(A|B) = \frac{p(B|A)p(A)}{p(B)},$$

na qual A e B são eventos de um espaço probabilístico com função probabilidade p, e $p(X|Y)$ representa a probabilidade condicional de X dado Y.

Adotando A como "o canditato j tem habilidade z" e B como "as respostas ao teste foram $(R_{ij})_{i=1}^{n}$", temos que $p(B|A)$ pode ser calculada diretamente em função dos parâmetros dos itens, mas para calcular $p(A)$ e $p(B)$ precisamos da distribuição da habilidade pela população de examinados.

Assim, a estimação bayesiana consiste em adotar uma distribuição *a priori* para as habilidades, a partir da qual obtém-se a distribuição *a posteriori* para a habilidade do candidato j (em função de suas respostas ao teste) aplicando o Teorema

de Bayes. Adota-se, então, alguma característica da distribuição *a posteriori* como estimador da habilidade.

As duas características mais utilizadas são a moda e a média, dando origem aos métodos conhecidos respectivamente como *maximum a posteriori – MAP* e *expected a posteriori – EAP*. Mais detalhes podem ser encontrados em [3].

2.2. **Estimação dos parâmetros do item conhecidas as habilidades.** Novamente supomos a aplicação de um teste com n itens a um grupo de N indivíduos, sendo que agora supomos conhecida a habilidade z_j do candidato número j, para todo $j \in \{1, 2, \ldots, N\}$, além da respostas R_{ij} dada pelo candidato número j ao item número i, com a mesma convenção adotada anteriormente.

O problema de determinar os parâmetros do item i depende, é claro, do modelo adotado e, em particular, do número de parâmetros que determinam a função p_i. Para cada item resolvemos um problema de otimização com esse número de parâmetros. A precisão do cálculo aumenta com o número de indivíduos aos quais o item foi aplicado [3], [6].

Aqui o método de máxima verosimilhança também pode ser aplicado. Dados os parâmetros de um determinado item, define-se a função p_i, e a partir dela podem ser calculadas as probabilidades $p_i(z_j)$ de o indivíduo j acertar o item i, para todo j. Como a resposta de um indivíduo a um item é independente da resposta de qualquer outro indivíduo ao mesmo item, o produto

$$I_i = \prod_{j=1}^{N} R_{ij} p_i(z) \cdot (1 - R_{ij})(1 - p_i(z))$$

representa a probabilidade de um grupo de examinados com habilidades z_j respondam ao item i exatamente como no resultado do teste aplicado. Como esse produto I_i depende apenas dos parâmetros da curva característica do item i, estimamos que tais parâmetros sejam aqueles que maximizan I_i. Na prática, é comum utilizarmos $\log(I_i)$ para realizar a otimização, pelos mesmos motivos expostos anteriormente.

Este processo de determinação dos parâmetros de um item é usualmente denominado de *calibração*.

Além do método de máxima verosimilhança, também podem ser aplicados métodos de estimação bayesiana, para os quais torna-se necessário adotar distribuições *a priori* para os valores dos parâmetros (mais detallhes em [3]).

2.3. **Estimação conjunta de parâmetros dos itens e habilidades.** As situações descritas nos dois casos anteriores são comuns quando já há um sistema de avaliação bem estabelecido baseado na TRI, com um grande banco de itens com parâmetros conhecidos e um amplo número de indivíduos com habilidade já estimada.

Qualquer sistema de avaliação baseado na TRI deve começar em algum momento, contudo. Este início representa o maior desafio computacional, pois a única informação disponível são as respostas R_{ij} (mantendo as convenções adotadas anteriormente), e a quantidade de parâmetros a estimar simultaneamente é tão grande que o respectivo problema de otimização global pode ser impraticável.

Uma possível solução é utilizar um processo interativo de "ida e volta", começando com uma estimativa inicial (grosseira) das habilidades, que pode ser por exemplo o número de acertos, ou o número de acertos normalizado com alguma técnica da teoria clássica dos testes.

A partir dessa estimativa inicial das habilidades, os parâmetros dos itens podem ser calculados como descrito em 2.2. Estes parâmetros são então utilizados para obter novos valores para as habilidades como descrito em 2.1. Repete-se o procedimento até que os valores tanto das habilidades como dos parâmetros tornem-se estáveis, ou outro critério de parada seja atingido.

Sabe-se, no entanto, que este tipo de procedimento pode gerar inconsistências, em especial em situações em que tanto o número de indivíduos avaliados como o número de itens aumenta.

Além disso, quando os cálculos são baseados no método de máxima verosimilhança não é possível estimar habilidade para indivíduos que respondam todos os itens corretamente ou todos os itens incorretamente. Da mesma forma, não é possível estimar parâmetros de itens que foram respondidos corretamente (ou incorretamente) por todos os examinados.

Uma alternativa para evitar essas (e outras) dificuldades é acrescentar hipóteses sobre a distribuição das habilidades na população em estudo, e às vezes sobre as distribuição dos parâmetros dos itens considerados. Dentre estes, destacam-se os métodos de *Máxima Verosimilhança Marginal* e, de novo, *Estimação Bayesiana* [3].

3. TRI no Enem

A partir do ano de 2009, o Exame Nacional do Ensino Médio, ENEM, passou a adotar o modelo ML3 para suas avaliações de múltipla escolha. Segundo o MEC (ver [2]), "esta decisão teve duas finalidades principais: (1) permitir a comparabilidade dos resultados entre os anos e (2) permitir a aplicação do Exame várias vezes ao ano".

Até que se atinja a finalidade (2), o ENEM é aplicado uma vez por ano, e a quantidade de inscritos tem ficado em torno de 9 milhões de pessoas nos últimos anos. Com a crescente utilização da nota do ENEM em processos seletivos para universidades (substituindo diversos vestibulares), o mero número de acertos nas provas, que têm 45 questões para cada uma das 4 áreas do conhecimento avaliadas, proporcionaria apenas 46 notas possíveis em cada uma e não seria suficiente para classificar e selecionar adequadamente os examinados.

Com o Modelo ML3 da TRI, a quantidade de notas possíveis para um exame com 45 questões é teoricamente igual a 2^{45}, pois o valor estimado do traço latente depende não só do número de acertos, mas sim de *quais* questões foram acertadas.

Ademais, a utilização do ML3 permite corrigir possíveis distorções geradas por candidatos que acertem um número inusualmente alto de questões de forma casual ("no chute"). Mesmo sendo baixa a probabilidade de isso ocorrer, o grande número de candidatos torna estes casos estatisticamente possíveis.

3.1. Escala de proficiência (habilidade).

O ENEM utiliza o termo *proficiência* para o traço latente medido em cada uma das 4 áreas do conhecimento. Um dos motivos é que a palavra *habilidade* é usada pelo MEC em outro contexto, de forma que cada exame avalia até 30 diferentes *habilidades*, agrupadas em *competências* [5].

A escala de proficiência em cada uma das quatro áreas foi estabelecida no exame de 2009, o primeiro a utilizar a TRI. Convencionou-se média 500 e desvio-padrão 100 para os valores das proficiências (medidos pelas notas) dos concluintes do ensino médio da rede pública que realizaram o exame naquele ano.

A partir daí, todos os itens utilizados em novos exames foram calibrados com base nessa mesma escala, de modo a manter as notas em exames futuros comparáveis àquelas atribuídas em 2009. Assim, por exemplo, uma nota 700 na prova de Matemática do ENEM 2016 indica uma proficiência de dois desvios padrões

acima da média dos candidatos concluintes do ensino médio da rede pública em 2009.

3.2. **Pretestes.** A seguir reproduzimos trechos de uma nota de imprensa divulgada pelo MEC no início de 2011 [4].

"Cada nova questão criada para as avaliações do ensino promovidas pelo Instituto Nacional de Estudos e Pesquisas Educacionais (Inep) passa por um pré-teste com estudantes de escolas públicas e particulares. Essas provas contemplam a diversidade da educação básica do país.

O pré-teste avalia cada item sob três aspectos: grau de dificuldade, nível de discriminação (o quanto o item consegue diferenciar as pessoas que sabem ou não) e probabilidade de acerto ao acaso, além da proporção de pessoas que escolhem cada alternativa de resposta oferecida na prova. Uma prova para pré-teste deve reunir itens de difícil, média e fácil resolução. O número de questões pode variar a cada teste.

(...) Os pré-testes podem ser aplicados a alunos do ensino fundamental e médio e da educação superior. "

A motivação para esta nota foi o vazamento de questões do exame de 2010 que gerou a reaplicação do exame para certo grupo de alunos. Compreensivelmente, não são divulgados maiores detalhes sobre os pretestes, mas sabe-se que continuam ocorrendo todos os anos.

Além dos aspectos citados no texto, o preteste também é usado para estimação dos parâmetros (calibração) das questões que podem vir a fazer parte do ENEM.

Ainda assim, cabe a possibilidade de novas questões, não pretestadas, serem incluídas nas provas do ENEM, e até mesmo de que os parâmetros de algumas questões sejam recalculados após a aplicação da prova, já que a quantidade de participantes dos pretestes é muito menor que a de participantes do ENEM.

Nossas análises indicam a presença de questões no exame com comportamento bem distinto do adequado, como exemplificamos mais adiante, especialmente nas primeiras edições do ENEM com a TRI.

4. Acessando os microdados do Enem

Neste trabalho utilizamos os microdados do ENEM disponíveis em `http://portal.inep.gov.br/microdados`. Os dados a partir de 2012 estão em formato `csv`. Devido à grande quantidade de informação disponível, escolhemos escrever rotinas para extrair apenas os dados de interesse, que foram, para cada

aluno: número de inscrição, ano do concurso, presença em cada uma das 4 provas, nota em cada uma das provas, respostas dadas pelo anuno para cada questão de cada uma das provas, tipo de cada uma das provas, gabarito de cada uma das provas.

5. Primeiras Análises

5.1. **Verificação de coerência.** O primeiro indício de que as notas do Enem não são atribuídas da forma tradicional é a quantidade de notas diferentes. Uma prova de 45 questões tem apenas 46 possibilidades para o número total de acertos de um candidato, no entanto a prova de Matemática do ENEM 2012, por exemplo, apresenta 6 406 notas diferentes (dentre 4 049 876 candidatos que compareceram à prova).

Sabemos que o ENEM utiliza o modelo ML3 da TRI para chegar a essas notas. Isto significa que o que determina a nota de um candidato é o conjunto de questões que ele acertou. Esta é uma boa forma de verificar a consistência dos dados. Após processar a informação, atribuímos a cada aluno um vetor de zeros e uns para cada prova (0 ou 1 na posição k significa que ele acertou ou errou, respectivamente, a questão número k). A seguir, percorremos o banco de dados registrando a nota correspondente a cada vetor, armazenando a informação em uma estrutura de dados do tipo *índice* (*hashtable*, em inglês). (Optamos por fazer este processamento em *Python* [11], utilizando a estrutura de dicionário). Cada vez que encontramos um vetor que já foi indexado, verificamos se a nota coincide.

Contrariamente à expectativa, encontramos alguns vetores para os quais foram atribuídas notas diferentes. A incidência é relativamente pequena. Por exemplo, na prova de Matemática de 2012 há 16 vetores para os quais notas diferentes foram atribuídas, dentre mais de 3 milhões de vetores diferentes. A tabela 5.1 mostra, para cada um desses 16 vetores, as notas encontradas e o número de ocorrências de cada uma.

Para os vetores nos quais uma nota ocorre muito mais vezes do que outra, especialmente se a nota de menor frequência ocorre apenas uma vez, é razoável supor que a nota "correta" é a mais frequente. Os casos mais delicados são aqueles em que há apenas uma ocorrência de cada uma das notas. Na falta de maiores informações sobre os motivos dessas discrepâncias, podemos escolher considerar como nota correta a média das notas, ou simplesmente ignorar esses vetores conflitivos de nossas análises posteriores.

TABELA 5.1. Padrões de Resposta com Notas Diferentes

Vetor de Acertos	Nota 1	Ocorrências	Nota 2	Ocorrências
0000000000000000000000000000000000000000000000	277.2	501	286.6	2
0000000000000000000001000000000000010100100000	312.4	1	299.8	1
0000000000111000001001000000000000000010010000	313.3	1142	317.2	3
0000000100000000000000000001001010000000000000	329.4	1	314.4	1
0000001010000000000000000000000000000000000000	306.0	4	319.3	1
0000010000010000000000000000000000110001000000	324.4	1	307.2	1
0000101001111000001001000000000000000010010000	399.8	1	395.0	1
0000101011000000000100000000000000000000000000	382.7	1	362.6	1
0000101110000000000000000000000000000000000000	380.3	1	363.6	8
0000110100000010000000010000000000000000000000	368.9	1	382.9	1
0000111110100000010000101000010000000000000000	463.4	1	469.4	4
0100100100001000000000001010000010100000000001	390.7	1	412.1	1
0101000000000010100010000100100010110010000010	320.0	1009	335.0	1
1000000000000001000000000000000000000000000000	280.0	2	290.0	1
1000010000000000010000101000010000000000000000	344.1	1	363.1	987
1000011000000000010000101000010000000000000000	381.9	1	398.6	5

Para este trabalho escolhemos utilizar a média ponderada das notas nos casos em que nenhuma opção ocorre com frequência maior do que o dobro da outra. Pouco antes de finalizar o texto pudemos verificar que algumas das incoerências ocorrem em provas especiais, como a versão em Braille. Assim, para análises posteriores recomendamos excluir essas provas especiais.

5.2. **Contribuição de cada questão para a nota do candidato.** Um dos desafios da utilização do TRI em um exame de massa como o ENEM é fornecer informações corretas e eficazes aos principais interessados, especialment alunos e professores do Ensino Médio. Uma pergunta importante que surge naturalmente é "Se eu não sei a resposta de uma questão, é melhor chutar ou deixar em branco?"

Teoricamente, acertar uma questão não diminui a nota do aluno, já que a probabilidade de acerto de qualquer questão é uma função crescente da proficiência (nota). Assim, a recomendação teoricamente correta é marcar alguma opção em todas as questões, para maximizar a nota final.

Para verificar este fato na prática, para cada questão, buscamos os vetores de acertos que diferem *apenas* nessa questão, e comparamos as notas. A expectativa

é que o acerto da questão aumente a nota, mas é razoável que em alguns casos a nota seja a mesma. Caso o acerto *diminua* a nota, estaremos diante de uma incoerência com relação ao modelo.

A tabela 5.2 mostra os resultados desta busca para a prova de Matemática do ENEM 2012. Para esta análise, escolhemos eliminar aqueles 16 vetores com mais de uma nota encontrados anteriormente.

Vemos que ocorrem algumas incoerências, em número muito pequeno em comparação com o total. Pouco antes da conclusão deste trabalho, comprovamos que as incoerências estão relacionadas a provas especiais (Braille, Libras, etc.).

5.3. **Funções probabilidade por proficiência para cada questão.** Uma maneira simples de observar a adequação do modelo TRI 3p aos dados concretos do ENEM é estimar as probabilidades de acerto de cada questão em função da proficiência (nota) do candidato.

Fizemos um primeiro teste com a prova de Matemática do ENEM 2010. Como as notas estão todas no intervalo $]300, 1000[$, dividimos este intervalo em subintervalos de tamanho 50. Para cada subintervalo determinamos o número de alunos com nota nesse subintervalo e calculamos quantos deles acertaram a questão. Um gráfico simples com esses valores (unindo os pontos com linhas retas) nos permite ter uma primeira sensação a respeito da adequação de cada questão. Por exemplo, o gráfico da questão 4 tem o seguinte aspecto:

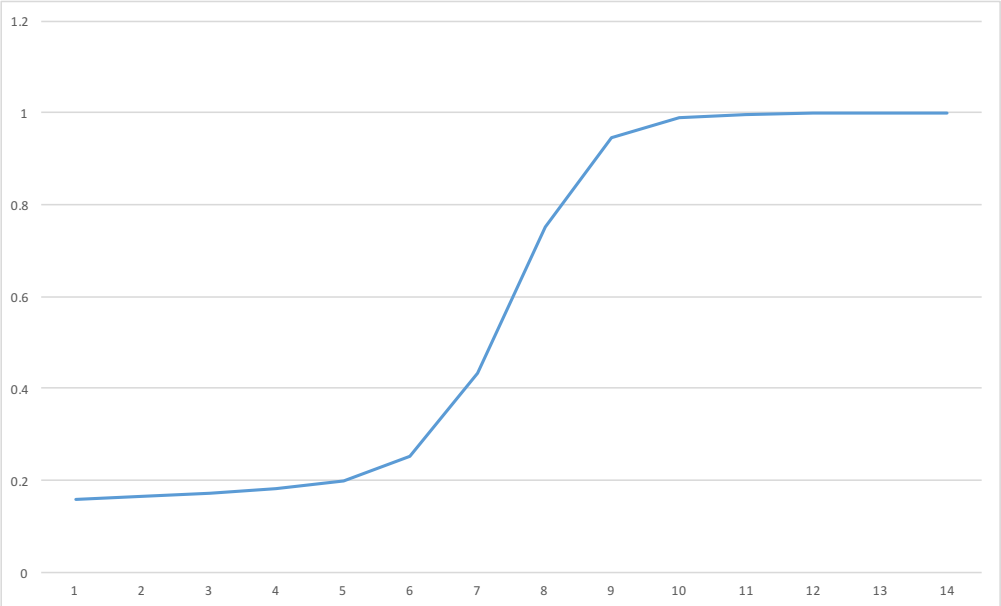

TABELA 5.2. Incoerências encontradas para o acerto de cada questão

Questão	Total	Maior	Igual	Menor
1	6694	6694	0	0
2	5010	5010	0	0
3	10951	10950	0	1
4	6937	6936	0	1
5	8036	8036	0	0
6	9632	9632	0	0
7	9089	9089	0	0
8	9084	9084	0	0
9	7298	7298	0	0
10	7474	7474	0	0
11	11720	11719	0	1
12	9361	8583	775	3
13	11930	11930	0	0
14	9132	9054	77	1
15	11954	11952	0	2
16	7579	7578	0	1
17	6967	6967	0	0
18	6939	6938	0	1
19	8506	8505	0	1
20	6037	6036	0	1
21	5368	5368	0	0
22	8904	8904	0	0
23	5914	5914	0	0
24	7041	7041	0	0
25	8844	8844	0	0
26	9302	9302	0	0
27	13100	13098	0	2
28	9997	9758	239	0
29	8538	8538	0	0
30	9496	5413	4083	0
31	8450	8450	0	0
32	7738	7738	0	0
33	5928	5927	0	1
34	9957	9956	0	1
35	9918	9918	0	0
36	7103	7102	0	1
37	7516	7247	269	0
38	9555	9555	0	0
39	10386	10386	0	0
40	8370	8370	0	0
41	9556	9409	147	0
42	9448	5755	3693	0
43	9863	9863	0	0
44	9648	9648	0	0
45	6881	5893	988	0

Observamos um formato muito próximo ao esperado, indicando que essa questão deve estar adequada ao modelo. O mesmo não ocorre, por exemplo, com a questão 21 desta mesma prova:

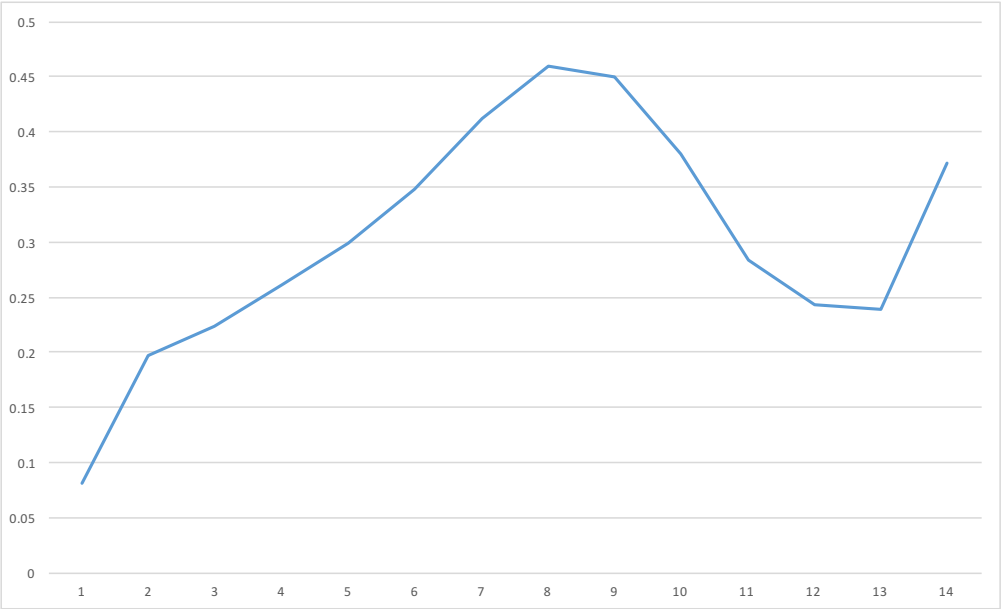

Este é um indício de que a questão não é adequada para a utilização do modelo ML3. Uma pergunta interessante é:

"Tal questão deveria ser anulada? Ou o próprio modelo se encarregará de lidar com ela de maneira aceitável?"

6. Estimação dos parâmetros de cada questão

Como vimos, analisando os microdados do ENEM podemos extrair bastante informação útil sobre o exame e sobre os efeitos da utilização do TRI nas notas. A informação não é completa, contudo. Sabemos que o modelo utilizado é o de três parâmetros, mas não temos acesso direto a esses parâmetros para as questões utilizadas. Tampouco conhecemos os detalhes do preteste (algo compreensível devido ao sigilo e segurança do exame).

A pergunta aparece naturalmente: "É possível determinar os parâmetros utilizados na implementação do ML3 a partir das informações contidas nos microdados?".

Nesta seção vamos explorar algumas alternativas para responder a essa pergunta. Acreditamos ser possível fazer estimativas razoáveis com métodos relativamente simples, sem a necessidade de utilizar demasiadas "caixas pretas" computacionais

e, principalmente, sem a necessidade de recorrer a programas comerciais de alto custo.

6.1. **Funções probabilidade de cada questão.** Já vimos em 5.3 uma forma simples de observar se o comportamento dos índices de acerto de uma questão em função da nota condiz com o ML3. Nossa primeira ideia para estimar os parâmetros de cada questão consiste em tratar as questões separadamente, buscando os parâmetros que mais bem se adaptem aos dados.

Começamos com uma ideia ingênua porém extremamente rápida e prática, reduzindo o problema ao cálculo do valor mínimo de uma função de três variáveis (para cada questão).

6.1.1. *Probabilidades por intervalos.* A ideia é dividir o eixo da proficiência (z) em subintervalos e estimar as probabilidades de acerto de cada questão em cada subintervalo. A estimativa é feita simplesmente dividindo o número de candidatos que acertaram a questão e têm nota no intervalo pelo total de candidatos com nota nesse intervalo.

A seguir, buscamos uma função probabilidade da forma

$$p(z) = c + \frac{1-c}{1+\exp(-a(z-b))}$$

que aproxime da melhor forma possível essas probabilidades estimadas.

Para isso, precisamos levar em conta a distribuição das notas no conjunto de candidatos, que admitimos ser normal. Isto é particularmente importante em intervalos relativamente grandes.

Em outras palavras, para calcular a probabilidade de acerto teórica de uma questão com função probabilidade p ao selecionar-se um aluno ao acaso cuja nota pertença ao intervalo $[a, b]$, devemos atribuir um "peso" a $p(t)$ proporcional a $d(t)$, onde d é a função densidade da distribuição de notas na população, ou seja, a probabilidade é igual a

$$p([a, b]) = \frac{\int_a^b d(t)p(t)dt}{\int_a^b d(t)dt}$$

Na prática, utilizamos para d a função densidade da distribuição normal com média e variança iguais às da amostra utilizada.

Quanto menor o número de intervalos, mais leves e rápidos são os cálculos envolvidos, e maior a confiabilidade da estimativa obtida através dos dados. Por

outro lado, um maior número de intervalos pode melhorar a precisão da estimativa dos parâmetros.

Para nossa implementação, decidimos escolher os intervalos de modo que o número de candidatos com nota em cada intervalo seja aproximadamente constante. Com isso obtemos um grau de confiança similar para a estimativa de probabilidade em cada intervalo, e portanto podemos considerar que todos têm o mesmo peso na determinação dos parâmetros. Outra vantagem é facilitar a representação gráfica.

Sendo N o número de notas maiores que zero presentes na amostra, e n o número de intervalos da divisão, determinamos os valores $a_0, a_1, \ldots, a_n$ tais que a quantidade de alunos com nota entre a_k e a_{k+1} é aproximadamnte $\frac{N}{n}$. A seguir, para cada questão, estimamos a probabilidade de acerto para um candidato com nota no intervalo $[a_{k-1}, a_{k+1}]$, para $k = 1, 2, \ldots, n-1$, encontrando um valor E_k (igual ao número de alunos com nota no intervalo que acertaram a questão dividido pelo total de alunos com nota no intervalo).

Este valor de E_k é nossa estivativa para $P_k = p([a_k, a_{k+1}])$. Agora podemos procurar os valores dos parâmetros a, b, c para os quais os respectivos valores de P_k mais se aproximam dos valores de E_k. Utilizando a norma euclidiana para medir distâncias, obtemos o seguinte problema de otimização: Determinar a, b, c para os quais a função

$$m(a, b, c) = \sum_{k=0}^{n} (P_k - E_k)^2$$

atinge seu valor mínimo.

Exemplo 6.1 (Aplicação à prova de Matemática do ENEM 2012)**.** Neste exemplo aplicamos o método com $n = 50$ aos dados da prova de Matemática do ENEM 2012. A otimização foi feita em R [8], através da função *optim* , método "BFGS". Após alguns testes, fica claro que o valor inicial do parâmetro b é o mais crítico para que o cálculo convirja adequadamente para o valor mínimo buscado, portanto implementamos uma rotina que aplica o método para diversos valores iniciais de b e seleciona o resultado mais adequado.

Uma forma de visualizar a adequação dos parâmetros é através do gráfico da função probabilidade. Espera-se que, para os parâmetros corretos, o gráfico seja aproximado pelos pontos (x_k, E_k).

No gráfico a seguir representamos os pontos (x_k, E_k) obtidos para a questão 9.

QUESTÃO 9, MATEMÁTICA, ENEM 2012

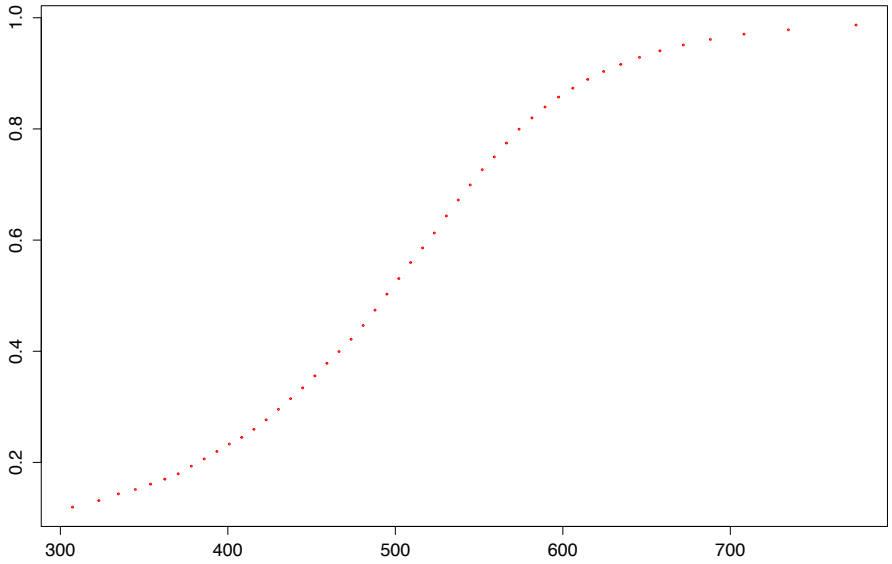

Olhando o gráfico já temos a impressão de que esta questão está bem formulada e adequada ao modelo. O valor de b é o mais fácil de adivinhar, parecendo estar um pouco acima de 500. Também é razoável esperar um valor de c próximo a $0,10$. Nossa rotina de otimização encontra os valores aproximados $a = 0,01776$, $b = 506,5$, $c = 0,1070$, e desenhando o gráfico da função probabilidade correspondente, em linha contínua, a aproximação parece, de fato, excelente:

QUESTÃO 9

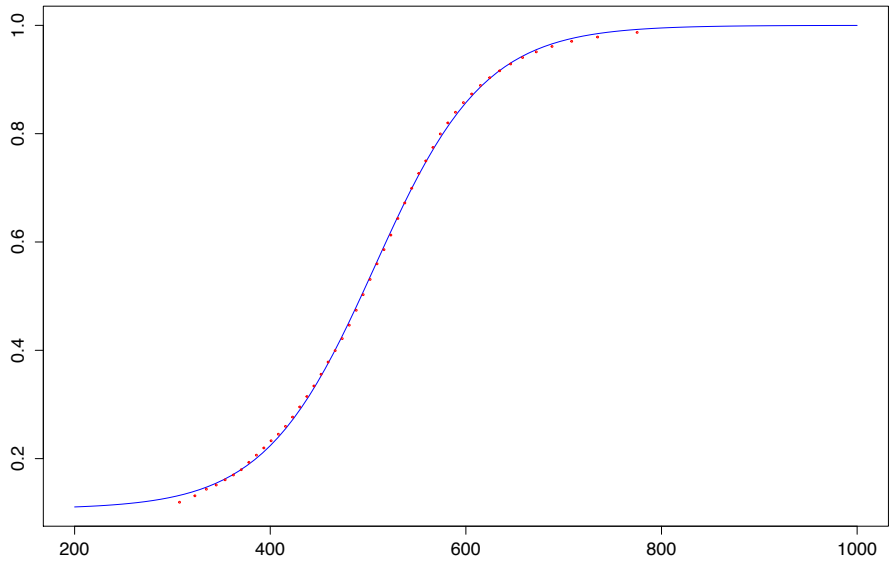

A comprovação matemática desta sensação é dada pelo valor da função que pretendemos minimizar, que neste caso é aproximadamente $m(a, b, c) = 1,12 \times 10^{-3}$.

De fato, a observação deste valor mínimo é uma boa forma de avaliar quais questões estão mais ou menos bem adaptadas ao modelo. Após aplicarmos nossa rotina de otimização a todas as questões, o menor valor que encontramos para $m(a, b, c)$ ocorre na questão 19 ($m(a, b, c) = 2,2 \times 10^{-4}$), enquanto o maior desses valores ocorre na questão 5 ($m(a, b, c) = 4,8 \times 10^{-2}$). Em ambos os casos, os gráficos também são reveladores:

Questão 19

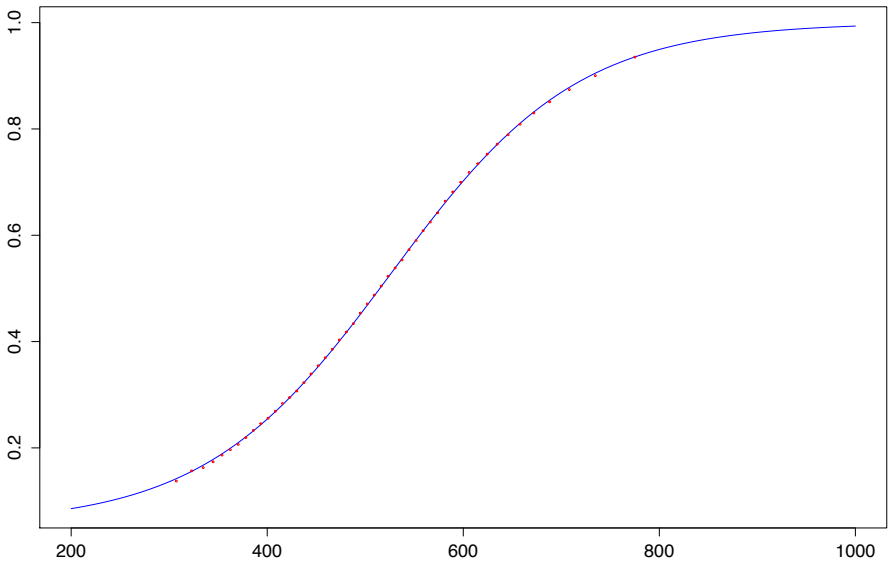

Questão 5

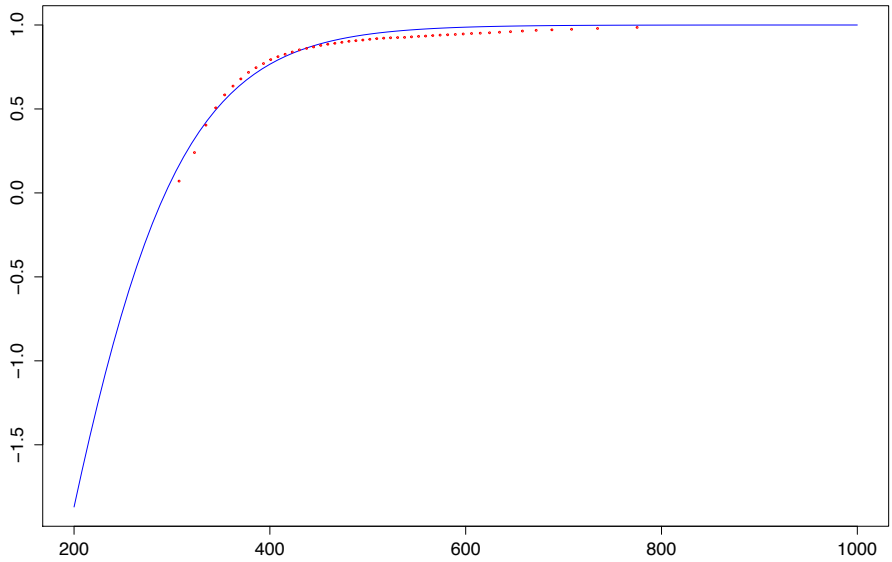

Observamos neste último gráfico maior irregularidade no desenho sugerido pelos pontos (x_k, E_k), e como a função probabilidade encontrada na otimização já não se ajusta tão bem a esses pontos. Ademais, destaca a obtenção de um valor negativo de c. Apesar de que teoricamente não é possível haver probabilidades de acerto negativas, na prática pode ser conveniente admitir tais valores para aumentar a flexibilidade do modelo. É o caso desta questão 5, para a qual essa flexibilidade permite ajustar melhor a curva aos dados.

Para exemplificar, adaptamos nosso método de otimização para exigir valores de c não negativos. O método, não surpreendentemente, encontra $c = 0$. O valor correspondente de $m(a, b, c)$ praticamente triplica para quase $0,15$, e o gráfico visualmente se afasta ainda mais dos pontos de aproximação:

Questão 5 otimizada com a restrição $c \geq 0$

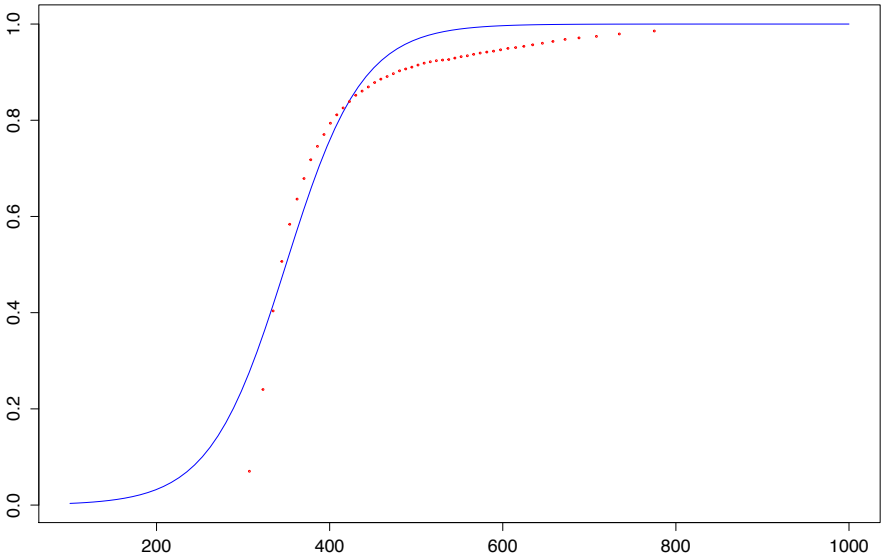

Mais alguns exemplos:

Questão 10

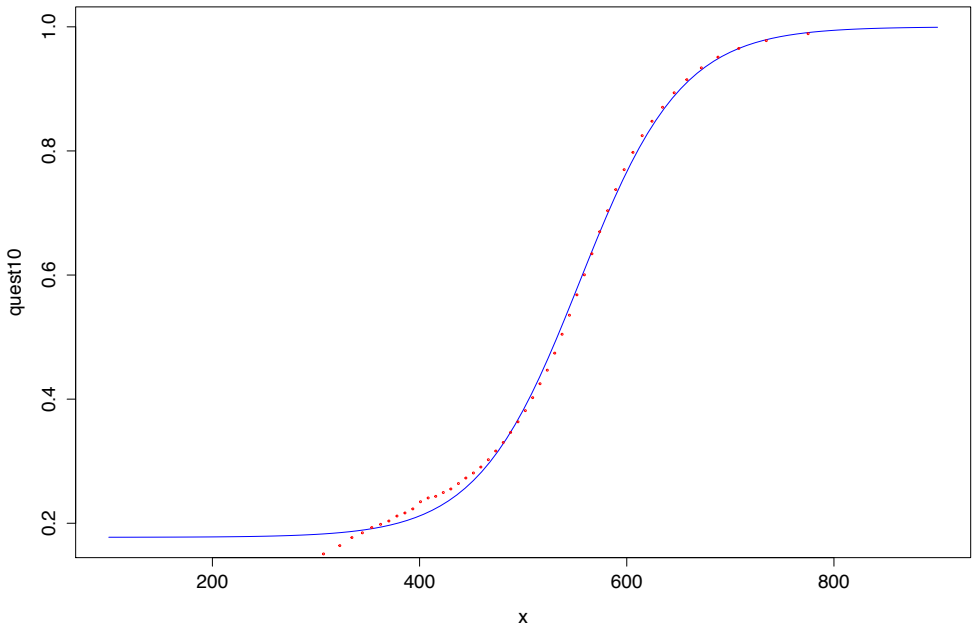

Questão 25

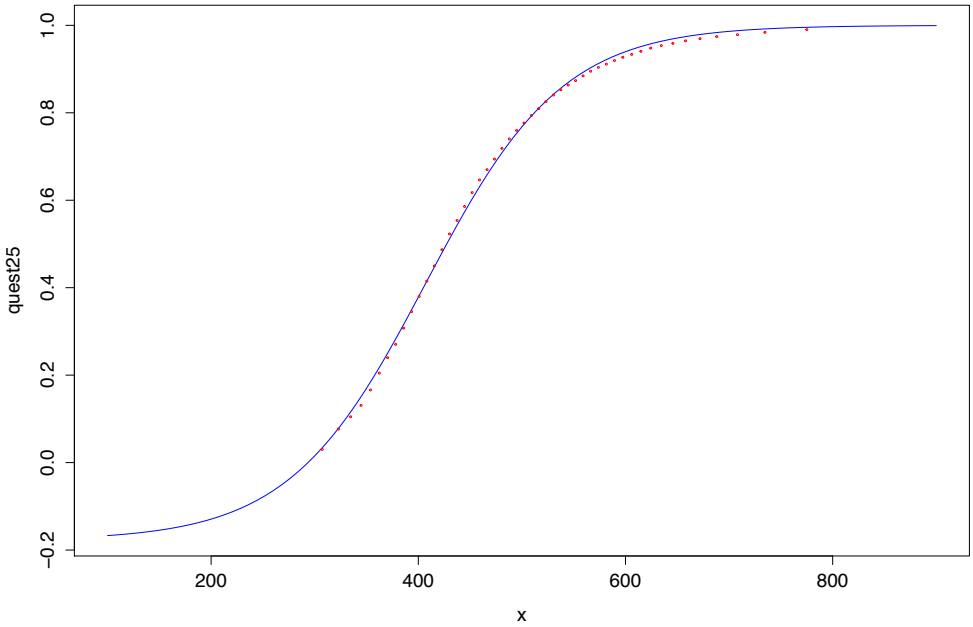
quest25
1.0
0.8
0.6
0.4
0.2
0.0
−0.2
200
400
600
800
x

Questão 31

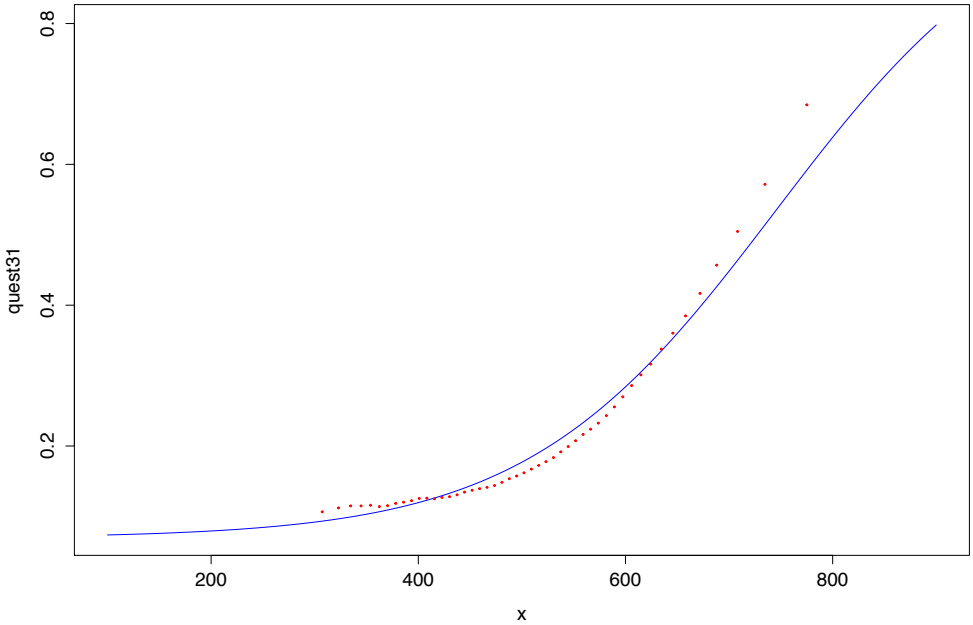
quest31
0.8
0.6
0.4
0.2
200
400
600
800
x

6.1.2. *Máxima Verosimilhança.* O método padrão para determinar parâmetros de uma função probabilidade a partir de uma amostra de resultados é o da *máxima verosimilhança.* Dados os três parâmetros de uma determinada questão, a partir da nota de cada aluno podemos determinar a probabilidade de ele acertar ou errar a questão. Mas também sabemos se cada aluno acertou ou errou a questão, e basta multiplicar essas probabilidades para obter a probabilidade de ocorrerem todos esses resultados observados juntos. A máxima verosimilhança é obtida com os parâmetros a, b, c para os quais essa probabilidade é máxima.

Como os valores das probabilidades são pequenos e em grande quantidade, é convenientre trabalhar com o logaritmo da função probabilidade. Dados a, b, c, a probabilidade de um aluno com nota (proficiência) z acertar a questão é

$$p(z) = c + \frac{1-c}{1+\exp(-a(z-b))} = c + \frac{(1-c)\exp(a(z-b))}{\exp(a(z-b))+1)} = \frac{c+\exp(a(z-b))}{\exp(a(z-b))+1},$$

e a probabilidade de errá-la é

$$1 - p(z) = \frac{1-c}{\exp(a(z-b))+1)+1}.$$

Assim, os logaritmos dessas probabilidades são

$$\log(p(z)) = \log(c + \exp(a(z-b))) - \log(\exp(a(z-b))+1),$$

e

$$\log(1-p(z)) = \log(1-c) - \log(\exp(a(z-b))+1).$$

Para obter a função que queremos maximizar, devemos somar os logaritmos das probabilidades de todos os resultados observados. Como o número de alunos é muito maior que a quantidade de notas possíveis, a maneira prática de fazer este cálculo é obter, para cada possível nota z, a quantidade a_z de alunos com essa nota que acertaram a questão e a quantidade e_z de alunos com essa nota que erraram a questão. Assim, a função a maximizar é dada por

$$\ell m(a, b, c) = \sum_z (a_z \log(p(z)) + e_z \log(1-p(z))),$$

onde a soma é feita sobre todas as notas z possíveis.

Vamos aplicar este método à mesma prova que usamos na seção anterior, e então poderemos comparar os resultados.

Exemplo 6.2 (Aplicação à prova de Matemática do ENEM 2012)**.** Novamente fizemos a otimização em R. O problema é essencialmente o mesmo do método

anterior: otimizar uma função de 3 variáveis, o que poderia ser feito novamente com a função *optim*. No entanto, preferimos aproveitar a função *mle*, específica para determinação da função de máxima verosimilhança. Internamente a otimização ainda é feita pela mesma função *optim*, e novamente escolhemos utilizar método "BFGS".

Uma vez mais a escolha do valor inicial de b é importante para a convergência adequada, e novamente implementamos uma rotina que fornece vários valores de b e escolhe a melhor opção.

Uma diferença importante com relação ao método anterior é que nem sempre obtemos convergência deixando livre o valor de c, pois valores muito pequenos de c (por exemplo $c < -1$) geram logaritmos de números negativos durante os cálculos, e o algoritmo de otimização é interrompido. Não surpreendentemente, as questões para as quais isso acontece para todos os valores inciais de b utilizados são algumas das que produziram valores negativos de c no método anterior. Nestes casos, adaptamos o método fixando $c = 0$.

Podemos usar os mesmos pontos (x_k, E_k) da seção anterior para visualizar a adequação das funções probabilidades obtidas. Vejamos, por exemplo, a questão 15, para a qual a probabilidade de máxima verosimilhança foi a maior dentre as 45 questões:

Questão 15

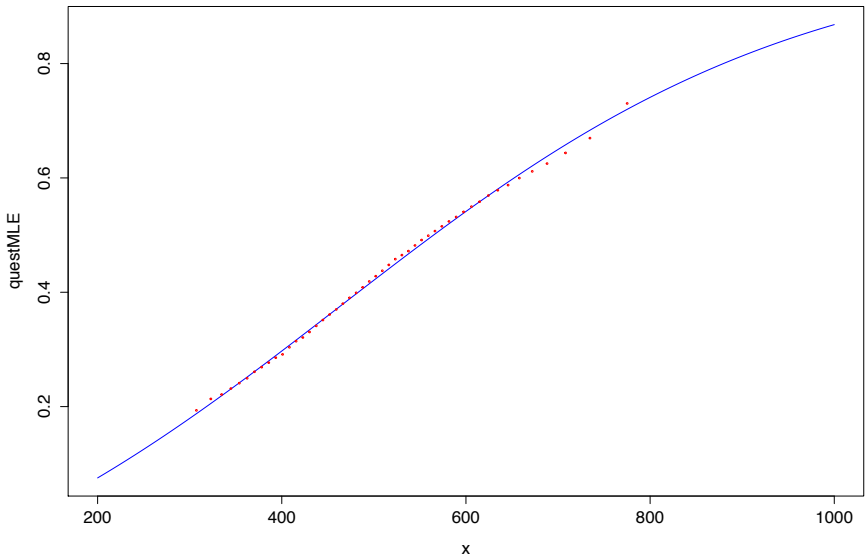

Por outro lado, a questão 5 foi aquela para a qual tal probabilidade foi a menor de todas. Foi também uma das questões para as quais tivemos que fixar $c = 0$ de maneira a conseguir a convergência do método. Eis o gráfico:

Questão 5

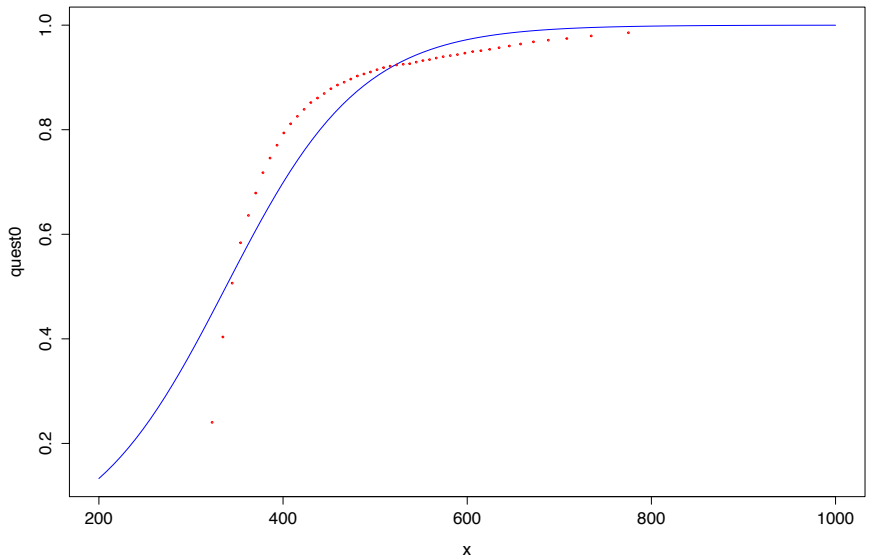

A tabela 6.1 mostra os valores a_1, b_1, c_1 obtidos pelo primeiro método e os valores a_2, b_2, c_2 obtidos pelo segundo método.

A mera observação nos convence de que ambos os métodos geram resultados muito parecidos. As questões para as quais os resultados diferem mais são de fato aquelas que parecem estar menos adequadas ao modelo.

A tabela 6.2 apresenta, para cada questão, o erro relativo ao considerarmos a_1 ou a_2 em relação à média entre a_1 e a_2, e analogamente para os parâmetros b e c.

Comprovaremos mais adiante que este método gera estimativa mais precisas para os parâmetros em relação ao anterior, no entanto é mais pesado computacionalmente, aumentando o tempo de execução. Uma forma de amenizar esta dificuldade é fornecer ao programa de otimização as derivadas parciais da função a ser otimizada ((a, b, c) neste caso).

6.2. **Utilização de pacotes de implementação do ML3.** A complexidade dos problemas computacionais relacionados com a implementação da TRI, juntamente

Tabela 6.1. Comparação

Questão	a_1	a_2	b_1	b_2	c_1	c_2
1	0.021619499	0.020512369	638.2246094	640.43391	0.132844647	0.13120028
2	0.017954166	0.017928522	652.655074	653.2527243	0.090281528	0.09059441
3	0.009245272	0.008547859	711.1746135	713.9337411	0.151828169	0.139938804
4	0.017111548	0.016776531	684.8496808	686.0066529	0.140183955	0.139341703
5	0.014580643	0.01358634	158.8870602	338.0564842	-7.097428757	0
6	0.010859658	0.01361823	358.6294865	428.4504451	-0.456596017	0
7	0.012034269	0.013521305	420.2644772	455.1525675	-0.192204146	0
8	0.010600114	0.010029325	478.3143879	464.1727006	-0.026784859	-0.09077819
9	0.017760998	0.017276605	506.5481435	504.5079374	0.106955478	0.096317205
10	0.020848239	0.020457435	556.0990005	554.6046045	0.18698638	0.181007124
11	0.006220833	0.005757075	643.2512587	636.104073	0.055666503	0.02761803
12	0.02700517	0.026505972	705.9336617	706.6796973	0.259187228	0.258509507
13	0.024803155	0.020830241	751.970975	762.3729	0.24354104	0.24083368
14	0.029586183	0.028018823	748.1841279	750.9642522	0.201528124	0.200882849
15	0.004341512	0.003982306	513.273913	463.4819749	-0.13079118	-0.248607361
16	0.01936241	0.02005629	676.557229	674.7212687	0.205419276	0.205682834
17	0.018463666	0.017163096	661.0975564	664.9048134	0.130909288	0.128319862
18	0.022898021	0.022590229	658.0382365	657.5758486	0.187966817	0.186177402
19	0.010499013	0.010289103	526.2076956	522.6989648	0.055936745	0.041504759
20	0.022658518	0.021712667	622.0944232	622.1530655	0.159153827	0.155654382
21	0.025881749	0.024966331	608.8131604	609.0437665	0.158729519	0.156269602
22	0.011709072	0.011424217	529.0315034	522.7033449	0.116573352	0.093420018
23	0.020886658	0.019914377	552.5854229	551.960028	0.101164434	0.09412691
24	0.016646197	0.015222663	565.5280242	563.3462537	0.10508249	0.087468398
25	0.014908409	0.017113702	403.0855945	434.8061599	-0.214185136	0
26	0.020480206	0.018568191	752.6233627	758.1074228	0.191483012	0.188634786
27	0.003385053	0.003151017	516.0076301	440.6010329	-0.126925778	-0.27163527
28	0.017988074	0.018285763	825.4817706	826.8977929	0.177413831	0.177868182
29	0.025312682	0.022303968	813.2993872	827.0965504	0.124020076	0.123978555
30	0.050701582	0.040521861	779.6101844	788.5450869	0.155877206	0.155415404
31	0.011683099	0.011589134	724.8251814	725.5059939	0.102005292	0.100880651
32	0.014689337	0.0154242	458.7109965	466.2333263	-0.038622763	0
33	0.032359299	0.030509598	645.5153701	646.566612	0.171444005	0.169795329
34	0.012121427	0.012287637	646.5966513	643.5071086	0.251074428	0.247226772
35	0.011541776	0.011294036	599.469079	594.5883585	0.220853861	0.207509345
36	0.014880083	0.015002863	577.0959428	576.1143925	0.135312955	0.133606606
37	0.023165344	0.025690016	877.8711335	872.060535	0.126901905	0.127225033
38	0.021402193	0.017874142	859.9572176	885.7314772	0.166576592	0.166152038
39	0.013163151	0.007407188	826.4602126	917.144943	0.208034673	0.186941659
40	0.021899377	0.019906506	818.6517369	830.68968	0.125913692	0.125827753
41	0.036635624	0.028702772	790.2487187	803.9231699	0.173990028	0.173235137
42	0.03654833	0.034062384	764.6006145	768.3750241	0.205539192	0.204902973
43	0.014335116	0.013697456	763.3668787	767.4958833	0.163788574	0.161469537
44	0.016761501	0.018887146	737.8404453	732.0672459	0.27717997	0.279685269
45	0.03709088	0.035169859	707.0853472	709.136109	0.166205311	0.166066092

Tabela 6.2. Erro relativo

Questão	Erro a	Erro b	Erro c
1	2.63%	0.17%	0.62%
2	0.07%	0.05%	0.17%
3	3.92%	0.19%	4.07%
4	0.99%	0.08%	0.30%
5	3.53%	36.05%	100.00%
6	11.27%	8.87%	100.00%
7	5.82%	3.99%	100.00%
8	2.77%	1.50%	54.43%
9	1.38%	0.20%	5.23%
10	0.95%	0.13%	1.62%
11	3.87%	0.56%	33.68%
12	0.93%	0.05%	0.13%
13	8.71%	0.69%	0.56%
14	2.72%	0.19%	0.16%
15	4.32%	5.10%	31.05%
16	1.76%	0.14%	0.06%
17	3.65%	0.29%	1.00%
18	0.68%	0.04%	0.48%
19	1.01%	0.33%	14.81%
20	2.13%	0.00%	1.11%
21	1.80%	0.02%	0.78%
22	1.23%	0.60%	11.03%
23	2.38%	0.06%	3.60%
24	4.47%	0.19%	9.15%
25	6.89%	3.79%	100.00%
26	4.90%	0.36%	0.75%
27	3.58%	7.88%	36.31%
28	0.82%	0.09%	0.13%
29	6.32%	0.84%	0.02%
30	11.16%	0.57%	0.15%
31	0.40%	0.05%	0.55%
32	2.44%	0.81%	100.00%
33	2.94%	0.08%	0.48%
34	0.68%	0.24%	0.77%
35	1.08%	0.41%	3.12%
36	0.41%	0.09%	0.63%
37	5.17%	0.33%	0.13%
38	8.98%	1.48%	0.13%
39	27.98%	5.20%	5.34%
40	4.77%	0.73%	0.03%
41	12.14%	0.86%	0.22%
42	3.52%	0.25%	0.16%
43	2.27%	0.27%	0.71%
44	5.96%	0.39%	0.45%
45	2.66%	0.14%	0.04%

à sua crescente utilização em importantes sistemas de avaliação ao redor do mundo, levou naturalmente ao desenvolvimento de pacotes de software especializados.

Tais pacotes estão preparados para estimação conjunta de traços latentes e curvas características dos itens partindo apenas do conjunto de respostas de um grupo de examinados aos itens de um teste, um problema muito mais complicado do que aquele que estamos tratando nesta seção.

Além dos pacotes citados em [3] e [6] (em sua maioria comerciais), já há opções de software livre disponíveis, como os pacotes *ltm* e *mirt* em R.

6.2.1. *Pacote ltm em R.* O pacote *ltm* em R [9] possui diversas opções para implementação de diferentes modelos de TRI (A sigla significa *Latent Trait Models*. Para o ML3, o pacote possui a função *tpm* (sigla para *three parameter model*. A maneira mais simples de utilizar essa função é fornecer como entrada apenas os vetores de acertos e erros correspondentes a todos os alunos que participaram da prova (uma matriz de zeros e uns). A função então processa os dados supondo que o traço latente seja medido em uma escala tal que, para a população testada, a média seja 0 e o desvio padrão, 1, e encontra os parâmetros mais adequados para cada questão, assim como o correspondente valor do traço latente para cada participante (mais precisamente, para cada vetor de acertos e erros). O resultado é um objeto que reúne diversas informações úteis sobre o modelo e sua adequação aos dados observados.

Aplicamos a função *tpm* aos dados da prova de Matemática do ENEM 2012, utilizando como entrada apenas a matriz de zeros e uns contendo os vetores de acertos e erros de todos os alunos. Observe que, diferentemente do que fizemos nos dois médodos anteriores, aqui não utilizamos a informação sobre a nota de cada aluno. A execução levou cerca de 45 horas em um MacBook Pro com processador Intel Core i7 de 3.1 GHz e 16 GB de memória. A primeira análise que fizemos foi comparar os valores obtidos para o traço latente (z) com os respectivos valores da nota atribuída pelo ENEM (E). O gráfico a seguir representa os $4\,049\,876$ pontos da forma (z, E) para cada um dos diferentes vetores de acertos e erros contidos nos dados. A expectativa é que esses pontos situem-se aproximadamente sobre uma reta. Utilizando o método de mínimos quadrados, calculamos a reta que mais bem aproxima esses pontos, e a representamos também no gráfico, em vermelho. O resultado é o seguinte:

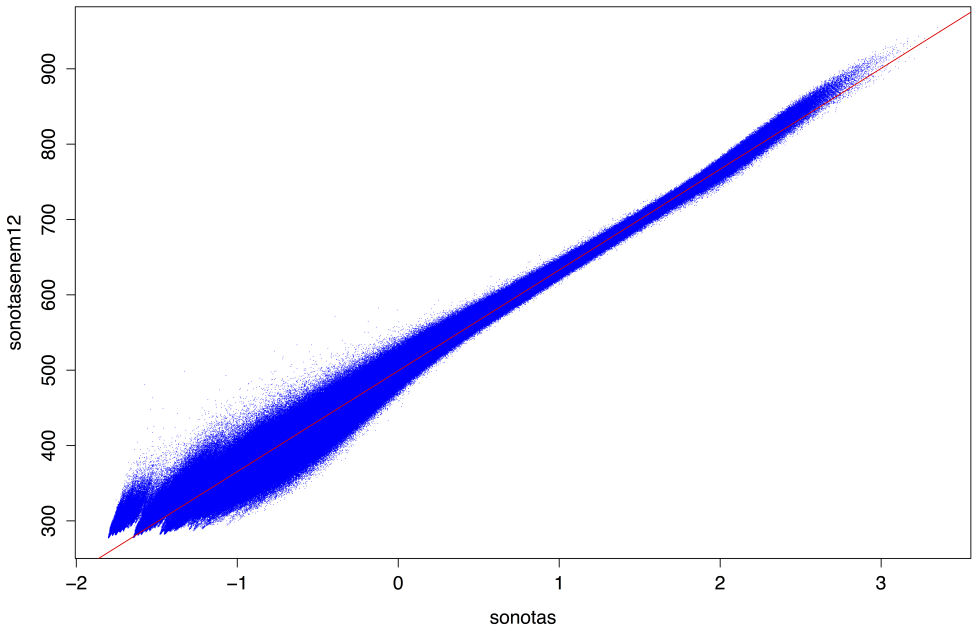

Os dados parecem ser razoavelmente compatíveis, observando-se maior variação na faixa de notas menores. É conhecido o fato de o ML3 apresentar maior imprecisão nas notas maiores e nas menores (sendo que estas últimas ocorrem em maior quantidade). A quantidade relativamente grande de ocorrências do vetor nulo também pode ajudar a explicar essa distorção.

A reta que mais bem aproxima a relação entre z e E, representada na figura, tem equação $E = 499,2 + 133,8z$. A expectativa teórica é de que os coeficientes dessa reta sejam iguais à média e ao desvio padrão das notas na escala do ENEM, que são, respectivamente $508,8$ e $121,2$. Ou seja, estamos diante de mais um indício de que os resultados obtidos são compatíveis com os dados.

A seguir, extraímos do objeto gerado pela função *tpm* os parâmetros de cada questão. Tais parâmetros também estão ajustados supondo uma distribuição normal do traço latente pela população, com média zero e desvio padrão 1. Para compará-los com aqueles obtidos nas seções anteriores, fazemos a conversão utilizando a média e desvio padrão observados em nossa amostra. Mais especificamente, sendo m a média e σ o desvio padrão observados, e a, b, c os parâmetros de uma determinada questão gerados pela função *tpm*, os respectivos valores na escala do ENEM serão $a_3 = a/\sigma$, $b_3 = m + \sigma b$ e $c_3 = c$. Na tabela 6.3 apresentamos os

resultados obtidos, juntamente com aqueles já obtidos pela utilização dos métodos anteriores para facilitar a comparação.

6.3. **Comparação dos Resultados.** O principal motivo para estimar os parâmetros das questões do ENEM é sermos capazes de reproduzir o cálculo das notas do exame. Isso nos permite, por exemplo, aplicar o mesmo exame a alunos que não o tenham feito (supondo, é claro, que não tenham visto as questões anteriormente) e calcular corretamente (ou com aceitável margem de erro) a nota que teriam obtido a partir das respostas dadas.

Melhor ainda, podemos elaborar exames com questões retiradas de diferentes edições do ENEM para estimar a proficiência de futuros candidatos ao ENEM na mesma escala utilizada pelo INEP, obtendo com boa margem de segurança a nota mais provável de cada aluno "caso o exame fosse hoje".

Assim, de posse das estimativas obtidas pelos três métodos expostos anteriormente, podemos usar o método da máxima verosimilhança para recalcular as notas dos examinados da prova de Matemática do ENEM 2012, e comparar os resultados obtidos com as notas reais obtidas no exame.

A tabela 6.4 mostra os resultados obtidos para uma amostra de alunos com notas variadas. A otimização foi feita supondo a proficiência (nota) variando de 0 a 2000.

A primeira linha representa o vetor nulo (candidatos que erraram todas as questões), e a última representa o vetor com todas as coordenadas iguais a 1 (candidatos que acertaram todas as questões). Conforme esperado, o método da máxima verosimilhança atribuiu como proficiência os extremos do intervalo nestes dois casos.

A maior discrepância ocorre para notas baixas, especialmente inferiores a 400. Para estas, os parâmetros encontrados pelo pacote ltm são os que geram os resultados mais distantes da nota atribuída pelo ENEM.

Tabela 6.3. Parâmetros calculados pelos três métodos

Questão	a_1	a_2	a_3	b_1	b_2	b_3	c_1	c_2	c_3
1	0.02162	0.02051	0.02033	638.2	640.4	643.7	0.1328	0.1312	0.1390
2	0.01795	0.01793	0.01839	652.7	653.3	654.8	0.0903	0.0906	0.0981
3	0.009245	0.008548	0.009087	711.2	713.9	715.0	0.1518	0.1399	0.1518
4	0.01711	0.01678	0.01733	684.8	686.0	685.6	0.1402	0.1393	0.1447
5	0.01458	0.01359	0.01030	158.9	338.1	309.4	-7.0974	0.0000	0.0021
6	0.01086	0.01362	0.01301	358.6	428.5	450.7	-0.4566	0.0000	0.1118
7	0.01203	0.01352	0.01199	420.3	455.2	456.0	-0.1922	0.0000	0.0000
8	0.01060	0.01003	0.01208	478.3	464.2	511.3	-0.0268	-0.0908	0.0951
9	0.01776	0.01728	0.01692	506.5	504.5	509.0	0.1070	0.0963	0.0972
10	0.02085	0.02046	0.02105	556.1	554.6	563.5	0.1870	0.1810	0.2029
11	0.006221	0.005757	0.007433	643.3	636.1	677.6	0.0557	0.0276	0.1376
12	0.02701	0.02651	0.02504	705.9	706.7	703.5	0.2592	0.2585	0.2580
13	0.02480	0.00125	0.02299	752.0	533.4	757.2	0.2435	-0.4185	0.2455
14	0.02959	0.02802	0.02841	748.2	751.0	744.8	0.2015	0.2009	0.2021
15	0.004342	0.003982	0.004966	513.3	463.5	572.6	-0.1308	-0.2486	0.0020
16	0.01936	0.02006	0.01960	676.6	674.7	672.4	0.2054	0.2057	0.2043
17	0.01846	0.01716	0.01806	661.1	664.9	666.0	0.1309	0.1283	0.1372
18	0.02290	0.02259	0.02186	658.0	657.6	656.3	0.1880	0.1862	0.1854
19	0.01050	0.01029	0.01075	526.2	522.7	539.1	0.0559	0.0415	0.0909
20	0.02266	0.02171	0.02244	622.1	622.2	627.7	0.1592	0.1557	0.1709
21	0.02588	0.02497	0.02404	608.8	609.0	612.5	0.1587	0.1563	0.1635
22	0.01171	0.01142	0.01405	529.0	522.7	560.7	0.1166	0.0934	0.2156
23	0.02089	0.01991	0.02072	552.6	552.0	563.3	0.1012	0.0941	0.1272
24	0.01665	0.01522	0.01758	565.5	563.3	579.0	0.1051	0.0875	0.1400
25	0.01491	0.01711	0.01576	403.1	434.8	455.3	-0.2142	0.0000	0.1065
26	0.02048	0.01857	0.01962	752.6	758.1	750.6	0.1915	0.1886	0.1904
27	0.003385	0.003151	0.004138	516.0	440.6	581.6	-0.1269	-0.2716	0.0012
28	0.01799	0.01829	0.01746	825.5	826.9	822.1	0.1774	0.1779	0.1771
29	0.02531	0.02230	0.02339	813.3	827.1	815.2	0.1240	0.1240	0.1248
30	0.05070	0.04052	0.04358	779.6	788.5	774.9	0.1559	0.1554	0.1559
31	0.01168	0.01159	0.01214	724.8	725.5	721.4	0.1020	0.1009	0.1044
32	0.01469	0.01542	0.01564	458.7	466.2	491.7	-0.0386	0.0000	0.1073
33	0.03236	0.03051	0.02855	645.5	646.6	651.8	0.1714	0.1698	0.1797
34	0.01212	0.01229	0.01523	646.6	643.5	658.2	0.2511	0.2472	0.2907
35	0.01154	0.01129	0.01368	599.5	594.6	617.0	0.2209	0.2075	0.2697
36	0.01488	0.01500	0.01529	577.1	576.1	586.6	0.1353	0.1336	0.1588
37	0.02317	0.02569	0.02344	877.9	872.1	864.5	0.1269	0.1272	0.1268
38	0.02140	0.01787	0.01928	860.0	885.7	870.1	0.1666	0.1662	0.1671
39	0.01316	0.00741	0.01288	826.5	917.1	820.9	0.2080	0.1869	0.2047
40	0.02190	0.01991	0.02096	818.7	830.7	818.0	0.1259	0.1258	0.1265
41	0.03664	0.02870	0.03023	790.2	803.9	791.2	0.1740	0.1732	0.1739
42	0.03655	0.03406	0.03190	764.6	768.4	761.9	0.2055	0.2049	0.2051
43	0.01434	0.01370	0.01411	763.4	767.5	764.6	0.1638	0.1615	0.1651
44	0.01676	0.01889	0.01894	737.8	732.1	728.1	0.2772	0.2797	0.2803
45	0.03709	0.03517	0.03317	707.1	709.1	706.5	0.1662	0.1661	0.1677

Tabela 6.4. Algumas notas calculadas

ENEM	Intervalos	Verosimilhança	Pacote ltm
277.2	0.0	0.0	0.0
279.5	0.0	115.8	0.0
282.5	95.7	195.1	146.8
296.5	170.0	257.0	192.4
307.3	325.6	312.9	304.9
322.2	330.4	310.5	321.1
331.4	293.2	293.2	0.0
331.5	317.8	357.2	268.3
344.8	0.0	205.4	0.0
345.6	362.8	337.5	344.6
362.9	269.5	364.5	321.3
382.5	394.4	400.0	388.2
406.6	396.4	404.7	406.4
425.5	430.5	431.4	427.1
443.4	386.5	419.3	0.0
450.0	470.5	471.4	484.8
500.0	510.0	505.4	518.2
500.0	501.0	498.8	508.4
553.1	553.2	554.0	559.7
584.9	583.9	580.3	585.6
606.1	611.1	610.8	615.2
647.2	649.3	651.8	652.1
687.7	685.7	690.4	686.6
738.0	731.9	738.4	730.7
801.8	784.9	798.8	783.6
838.5	815.9	825.0	819.1
883.8	844.5	859.8	851.4
904.9	929.4	939.3	924.1
925.5	918.5	942.0	920.8
926.8	942.0	989.9	938.4
928.4	1067.4	1148.2	1050.4
928.6	932.3	952.5	934.7
955.2	2000.0	2000.0	2000.0

A partir de 400, com raras exceções, os três métodos geram valores muito próximos aos da nota do ENEM. Vamos usar a média quadrática das diferenças para comparar de forma mais precisa esses resultados. Assim, sendo p_j a proficiência calculada para o candidato j e n_j a nota atríbuída pelo ENEM, calculamos $\frac{1}{N}\sum_{j=1}^{N}(p_j - n_j)^2$ para os resultados de cada um dos métodos (N é o total de candidatos). Os resultados são os seguintes:

Método	Média Quadrática
Intervalos	41.51850
Verosimilhança	32.38593
Pacote ltm	61.52071

Por esta métrica, os resultados do método de máxima verosimilhança são melhores, e os obtidos pelo pacote ltm são significativamente piores. Como as maiores discrepâncias ocorrem para notas pequenas, refizemos o cálculo considerando apenas candidatos com notas acima de 400, obtendo os seguintes valores:

Método	Média Quadrática (nota > 400)
Intervalos	13.62272
Verosimilhança	12.37226
Pacote ltm	18.85429

Todos os resultados melhoram, mas ainda percebe-se maior desvio nos resultados do pacote ltm. A seguir apresentamos os resultados obtidos restringindo a cálculo a candidatos com notas ainda mais altas:

Método	Média Quadrática (nota > 500)
Intervalos	12.39387
Verosimilhança	11.91649
Pacote ltm	12.44167

Método	Média Quadrática (nota > 600)
Intervalos	15.13631
Verosimilhança	15.08925
Pacote ltm	15.02687

Método	Média Quadrática (nota > 700)
Intervalos	26.35282
Verosimilhança	26.09529
Pacote ltm	26.09587

Notamos que em todos os métodos as notas mais distantes da média geram um maior desvio médio, e para notas altas os três métodos geram resultados muito parecidos, sendo o método dos intervalos ligeiramente menos preciso.

Não obstante, os parâmetros calculados pelos três métodos são suficientes para reproduzir as notas atribuídas pelo ENEM com intervalo de confiança aceitável.

Para aplicações práticas como elaboração de simulados para avaliação de candidatos a edições futuras do ENEM, as discrepâncias significativas encontradas para notas baixas podem ser resolvidas, por exemplo, agrupando os participantes com nota estimada abaixo de 400 em um único grupo, e os demais por faixas de nota de amplitude 50 ou 100.

7. Simulações

Nesta seção realizamos algumas simulações de respostas a um exame de 45 questões similar aos do ENEM, supondo que os itens se comportam como no ML3. Geramos aleatoriamente uma amostra com 100 000 valores de habilidade supondo uma distribuição normal com média 500 e desvio padrão 100, para simular os valores intrínsecos de proficiência de um grupo de candidatos do ENEM.

Escolhemos este tamanho de examinados porque, nos testes iniciais, tamanhos muito maiores demandavam muito tempo de computação para o pacote ltm, enquanto tamanhos muito menores apresentavam mais distorções no cálculo dos parâmetros.

Geramos então 25 simulações de aplicação deste mesmo exame à mesma população, supondo que as probabilidades de acerto sejam dadas exatamente pelo valor das funções probabilidade de cada item calculadas no valor da proficiência suposta para cada candidato.

A seguir, para cada uma das simulações calculamos as notas dos candidatos pelo método de máxima verosimilhança.

Observemos, por exemplo, os resultados obtidos para um candidato com proficiência teórica de 511.1 (próxima à média): 536.7, 506.1, 531.1, 479.5, 527.3, 528.0, 488.2, 526.7, 517.5, 529.0, 520.4, 550.2, 524.7, 514.7, 514.3, 488.3, 567.1, 502.4, 485.5, 551.1, 509.4, 493.6, 499.1, 518.0, 517.8 .

A média dos valores é 517.1, e o desvio padrão, 21.6. A diferença entre os valores máximo (567.1) e mínimo (479.5) é 87.6.

Podemos observar nesta simulação o conhecido fato teórico de que o intervalo de confiança para a estimativa da proficiência é maior para valores muito pequenos

ou muito grandes. Por exemplo, para o candidato com proficiência mínima (68.9) na população simulada, os 25 valores obtidos apresentaram média de 58.8, desvio padrão 80.8, valor mínimo 0.00004 e máximo 199.9, diferença de 199.9.

Já para o candidato de proficiência máxima (919.6), a média foi de 923.5, com desvio padrão 35.7, mínimo 859.1 e máximo 981.5, diferença de 122.4.

7.1. **Estimação dos parâmetros.** Aplicamos às simulações os métodos de estimação dos parâmetros apresentados na seção 6. Isto é especialmente interessante por termos os valores teóricos previamente estabelecidos, e sabemos que os candidatos e itens se comportam como prevê o modelo.

A tabela 7.1 mostra os valores teóricos dos parâmetros das 45 questões usadas na simulação.

7.1.1. *Utilização do Pacote ltm.* Para cada um dos parâmetros de cada uma das questões calculamos a média e o desvio padrão das estimativas obtidas nas 25 simulações, e o resultado é o da tabela 7.2.

O método obtém excelentes aproximações para os valores teóricos de a, b e c para quase todas as questões. Observamos que as questões para as quais a estimação "falha" são normalmente as que têm valor de b muito alto (questões normalmente consideradas "difíceis"). Mas também chama atenção o ocorrido na questão 36, para a qual temos um valor de a muito baixo: nela, a estimativa do parâmetro b também ficou distante do valor teórico.

7.1.2. *Probabilidades por Intervalos.*

A tabela 7.3 mostra os resultados obtidos pelo métido dos intervalos. Também observamos maiores desvios nas questões com alto valor de b, mas em comparação com o método anterior há mais distorções no cálculo do valor de a. Em particular, chama à atenção a média negativa para o valor de a na questão 15, o que não é desejável para o ML3. Uma forma de tentar entender este fenômeno é utilizar o gráfico de pontos gerados pelo método dos intervalos junto com a curva característica correspondente.

Tabela 7.1. Parâmetros teóricos

Questão	a	b	c
1	0.0197067488522676	550.435295887291	0.184954829606716
2	0.0238312813728355	836.665037460625	0.21602782498834
3	0.0220230030636324	654.386280663311	0.25122567152464
4	0.0247244739891449	574.39585160464	0.11792326151752
5	0.0371338562037699	287.453964166343	0.103962361179138
6	0.0141605820131239	802.424083277583	0.16765568679491
7	0.0374112680314424	705.60046248138	0.113331933537266
8	0.0114372462314064	273.740872181952	0.141428466180384
9	0.0102550429217144	275.762750394642	0.142151339312684
10	0.0152032570953023	242.895813845098	0.182485228330536
11	0.0107169826430301	717.620867490768	0.170366725982119
12	0.0108761936926904	214.058205299079	0.225976594084533
13	0.0120577158496785	532.736649364233	0.161818464856632
14	0.0249512484198654	737.982819974422	0.236587248965058
15	0.0448478685839695	963.007104769349	0.187180136401572
16	0.0377760205175576	517.656419239938	0.170196117952011
17	0.00775021825279949	354.391607642174	0.188067964987767
18	0.0121782139399517	250.426792353392	0.167723467134154
19	0.00434226328045081	457.482335343957	0.230759270813955
20	0.020318632437173	281.150796636939	0.265876504768975
21	0.0240891904567818	838.900429941714	0.153752428859132
22	0.0182081099285424	442.058537714183	0.254055021949833
23	0.0251237404896852	545.448714867234	0.218304828202107
24	0.0366608052756542	811.955851502717	0.135847501641977
25	0.0190307769254269	986.697643436491	0.177596861686379
26	0.0195845127027059	927.117474935949	0.0937864523549255
27	0.0211647522241814	677.990544959903	0.204802068997686
28	0.00128779101193469	912.607763148844	0.2389866339033
29	0.0410566197591057	396.331079676747	0.27824521772894
30	0.0370487133787167	476.208012364805	0.22527892180029
31	0.0211010971107071	649.204517900944	0.161208452372023
32	0.0286067716256618	224.684945121408	0.182687920381323
33	0.0257290891800457	602.044633217156	0.166366502566288
34	0.0318079092359305	456.451249308884	0.21274444733497
35	0.0120153538944108	621.832576580346	0.147192815412599
36	0.000786316960175299	613.69231492281	0.294268530625516
37	0.01440115651982	948.036685585976	0.107802949126489
38	0.0013643258302238	825.392068363726	0.18003324015085
39	0.0195922186164684	220.114263519645	0.254866709456081
40	0.0204561126315955	928.935340605676	0.102051848468785
41	0.0343634384007966	431.23982809484	0.237943309438914
42	0.0273688193576483	663.77356313169	0.215090413402355
43	0.033239495380939	683.527742139995	0.145516575740924
44	0.0187730449362344	203.74394133687	0.338579978011088
45	0.0230873317664803	558.977637626231	0.222917044690049

Tabela 7.2. Estimativas (pacote ltm)

Questão	a	média a	desvio a	b	média b	desvio b	c	média c	desvio c
1	0.0197	0.0196	0.0004	550.4	550.3	1.2	0.185	0.184	0.0045
2	0.0238	0.0095	0.0093	836.7	1683.3	844.0	0.216	0.180	0.0429
3	0.0220	0.0218	0.0005	654.4	655.2	1.3	0.251	0.251	0.0028
4	0.0247	0.0245	0.0004	574.4	574.5	0.6	0.118	0.117	0.0027
5	0.0371	0.0447	0.0414	287.5	285.8	14.5	0.104	0.078	0.0984
6	0.0142	0.0144	0.0012	802.4	802.4	8.2	0.168	0.168	0.0027
7	0.0374	0.0371	0.0011	705.6	706.8	1.3	0.113	0.113	0.0009
8	0.0114	0.0114	0.0004	273.7	272.8	20.0	0.141	0.136	0.1110
9	0.0103	0.0102	0.0004	275.8	268.8	20.0	0.142	0.101	0.0992
10	0.0152	0.0151	0.0004	242.9	239.5	13.9	0.182	0.160	0.1045
11	0.0107	0.0106	0.0005	717.6	718.2	3.3	0.170	0.169	0.0046
12	0.0109	0.0108	0.0003	214.1	204.2	25.2	0.226	0.161	0.1488
13	0.0121	0.0121	0.0002	532.7	532.8	2.2	0.162	0.163	0.0078
14	0.0250	0.0247	0.0016	738.0	739.1	2.9	0.237	0.236	0.0019
15	0.0448	0.0008	0.0040	963.0	-12241.9	35930.6	0.187	0.096	0.0559
16	0.0378	0.0374	0.0006	517.7	517.2	0.6	0.170	0.169	0.0034
17	0.0078	0.0075	0.0004	354.4	339.9	24.7	0.188	0.140	0.0832
18	0.0122	0.0120	0.0003	250.4	244.2	15.5	0.168	0.136	0.0974
19	0.0043	0.0041	0.0005	457.5	413.6	62.2	0.231	0.156	0.1041
20	0.0203	0.0200	0.0006	281.2	274.5	9.6	0.266	0.212	0.0790
21	0.0241	0.0101	0.0099	838.9	2034.6	1260.2	0.154	0.108	0.0499
22	0.0182	0.0182	0.0003	442.1	442.3	2.4	0.254	0.255	0.0111
23	0.0251	0.0250	0.0005	545.4	545.6	0.9	0.218	0.218	0.0035
24	0.0367	0.0232	0.0156	812.0	1463.7	1109.0	0.136	0.117	0.0318
25	0.0190	0.0009	0.0039	986.7	-6222.2	86320.4	0.178	0.084	0.0557
26	0.0196	0.0056	0.0068	927.1	4547.1	3910.3	0.094	0.068	0.0290
27	0.0212	0.0208	0.0006	678.0	678.8	1.5	0.205	0.204	0.0024
28	0.0013	0.0011	0.0002	912.6	676.2	205.4	0.239	0.126	0.0989
29	0.0411	0.0619	0.0599	396.3	400.2	9.6	0.278	0.295	0.0321
30	0.0370	0.0368	0.0008	476.2	476.0	0.9	0.225	0.225	0.0056
31	0.0211	0.0211	0.0005	649.2	649.5	0.8	0.161	0.161	0.0024
32	0.0286	0.0283	0.0013	224.7	219.6	11.6	0.183	0.112	0.1427
33	0.0257	0.0256	0.0005	602.0	602.2	0.7	0.166	0.166	0.0025
34	0.0318	0.0316	0.0005	456.5	456.3	0.9	0.213	0.214	0.0062
35	0.0120	0.0119	0.0003	621.8	622.0	1.4	0.147	0.146	0.0049
36	0.0008	0.0006	0.0001	613.7	43.7	334.3	0.294	0.137	0.0893
37	0.0144	0.0022	0.0037	948.0	3539.2	1447.4	0.108	0.041	0.0353
38	0.0014	0.0012	0.0002	825.4	659.8	134.2	0.180	0.088	0.0737
39	0.0196	0.0196	0.0007	220.1	217.2	14.8	0.255	0.219	0.1359
40	0.0205	0.0062	0.0066	928.9	5385.3	14499.4	0.102	0.080	0.0390
41	0.0344	0.0341	0.0006	431.2	430.8	0.9	0.238	0.237	0.0064
42	0.0274	0.0272	0.0008	663.8	664.3	1.1	0.215	0.215	0.0022
43	0.0332	0.0330	0.0015	683.5	684.4	1.1	0.146	0.146	0.0014
44	0.0188	0.0189	0.0007	203.7	199.3	19.4	0.339	0.266	0.1813
45	0.0231	0.0230	0.0004	559.0	559.0	1.1	0.223	0.223	0.0040

TABELA 7.3. Estimativas (intervalos)

Questão	a	média a	desvio a	b	média b	desvio b	c	média c	desvio c
1	0.0197	0.0218	0.0004	550.4	552.7	1.8	0.185	0.185	0.006
2	0.0238	0.0548	0.0546	836.7	837.4	39.8	0.216	0.216	0.002
3	0.022	0.0261	0.0010	654.4	653.1	3.4	0.251	0.251	0.003
4	0.0247	0.0299	0.0006	574.4	578.8	4.4	0.118	0.125	0.010
5	0.0371	0.1018	0.0049	287.5	296.0	1.1	0.104	0.179	0.022
6	0.0142	0.0154	0.0005	802.4	800.1	0.7	0.168	0.169	0.002
7	0.0374	0.9906	0.5304	705.6	703.8	2.0	0.113	0.117	0.003
8	0.0114	0.0126	0.0008	273.7	280.5	38.8	0.141	0.091	0.396
9	0.0103	0.0112	0.0006	275.8	285.2	27.9	0.142	0.135	0.168
10	0.0152	0.0183	0.0007	242.9	273.3	10.5	0.182	0.339	0.065
11	0.0107	0.0124	0.0011	717.6	707.5	9.6	0.17	0.174	0.007
12	0.0109	0.0115	0.0007	214.1	212.7	32.1	0.226	0.152	0.165
13	0.0121	0.0110	0.0015	532.7	515.6	17.6	0.162	0.084	0.069
14	0.025	0.0173	0.0050	738	788.3	23.4	0.237	0.230	0.003
15	0.0448	-0.5682	1.6150	963	578.7	274.4	0.187	-0.268	0.403
16	0.0378	0.0606	0.0014	517.7	520.2	0.4	0.17	0.171	0.003
17	0.0078	0.0081	0.0007	354.4	357.8	49.0	0.188	0.175	0.179
18	0.0122	0.0137	0.0006	250.4	274.0	21.5	0.168	0.258	0.144
19	0.0043	0.0044	0.0004	457.5	450.0	69.3	0.231	0.209	0.128
20	0.0203	0.0319	0.0030	281.2	311.5	6.8	0.266	0.423	0.045
21	0.0241	1.6222	7.7168	838.9	838.3	36.9	0.154	0.154	0.002
22	0.0182	0.0193	0.0004	442.1	441.7	2.6	0.254	0.236	0.011
23	0.0251	0.0304	0.0005	545.4	549.2	0.9	0.218	0.223	0.004
24	0.0367	17.7350	25.9868	812	803.5	11.5	0.136	0.136	0.001
25	0.019	0.0194	0.0622	986.7	760.2	320.7	0.178	-0.020	0.350
26	0.0196	1.6186	4.3376	927.1	884.6	153.0	0.094	-0.015	0.293
27	0.0212	0.0209	0.0028	678	691.2	10.0	0.205	0.205	0.003
28	0.0013	0.0011	0.0003	912.6	572.0	151.8	0.239	0.081	0.087
29	0.0411	0.1040	0.0032	396.3	393.2	0.4	0.278	0.223	0.004
30	0.037	0.0576	0.0016	476.2	477.6	0.5	0.225	0.218	0.003
31	0.0211	0.0244	0.0006	649.2	650.8	1.0	0.161	0.163	0.002
32	0.0286	0.0514	0.0064	224.7	269.9	15.6	0.183	0.586	0.161
33	0.0257	0.0321	0.0006	602	603.6	2.1	0.166	0.168	0.004
34	0.0318	0.0432	0.0009	456.5	458.3	0.7	0.213	0.204	0.005
35	0.012	0.0111	0.0012	621.8	609.2	12.3	0.147	0.096	0.040
36	0.0008	0.0007	0.0001	613.7	504.1	110.1	0.294	0.262	0.034
37	0.0144	0.0368	0.1021	948	920.6	101.3	0.108	0.073	0.173
38	0.0014	0.0013	0.0006	825.4	597.8	199.5	0.18	0.067	0.133
39	0.0196	0.0296	0.0033	220.1	276.5	19.4	0.255	0.587	0.118
40	0.0205	1.7713	4.7498	928.9	882.3	150.2	0.102	-0.005	0.291
41	0.0344	0.0547	0.0012	431.2	433.0	0.5	0.238	0.228	0.004
42	0.0274	0.0347	0.0010	663.8	664.7	0.9	0.215	0.216	0.002
43	0.0332	0.0417	0.0060	683.5	688.3	7.2	0.146	0.145	0.001
44	0.0188	0.0275	0.0024	203.7	268.8	18.3	0.339	0.666	0.093
45	0.0231	0.0264	0.0014	559	559.3	5.3	0.223	0.217	0.017

Primeiramente, observamos a curva com os parâmetros teóricos, juntamente com os pontos gerados pela simulação número 6, que foi a que gerou o menor valor de a neste método:

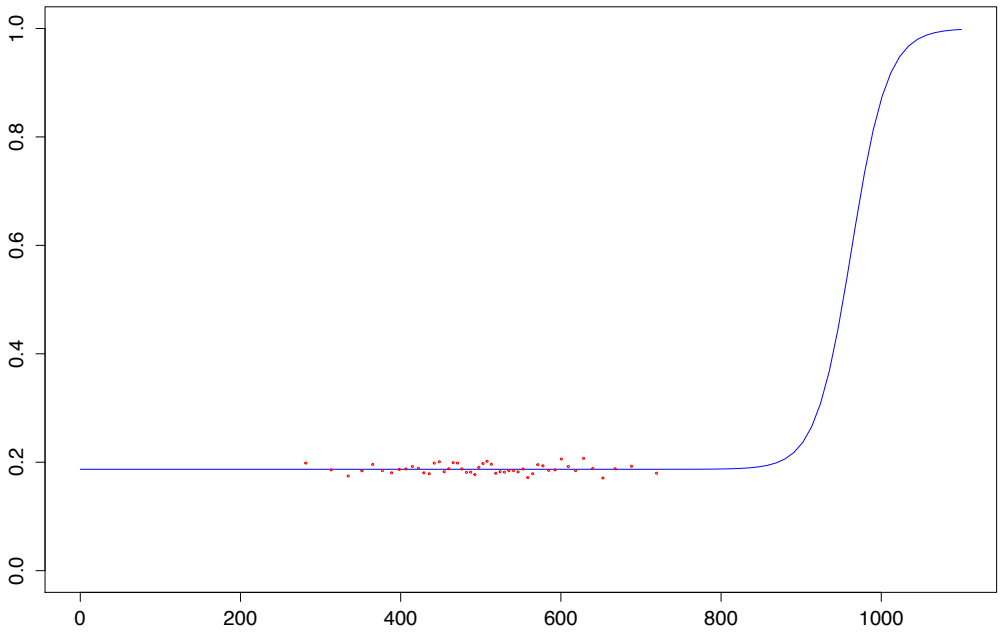

Notamos que em nenhum dos intervalos gerados a probabilidade estimada pelos resultados observados supera significativamente o valor de c. Ou seja, o método dos intervalos não gera informação suficiente, neste caso para estimar corretamente os parâmetros.

Observemos o gráfico gerado pelos parâmetros obtidos a partir desta simulação, que foram $a = -5.16, b = 151.0, c = 0.188$:

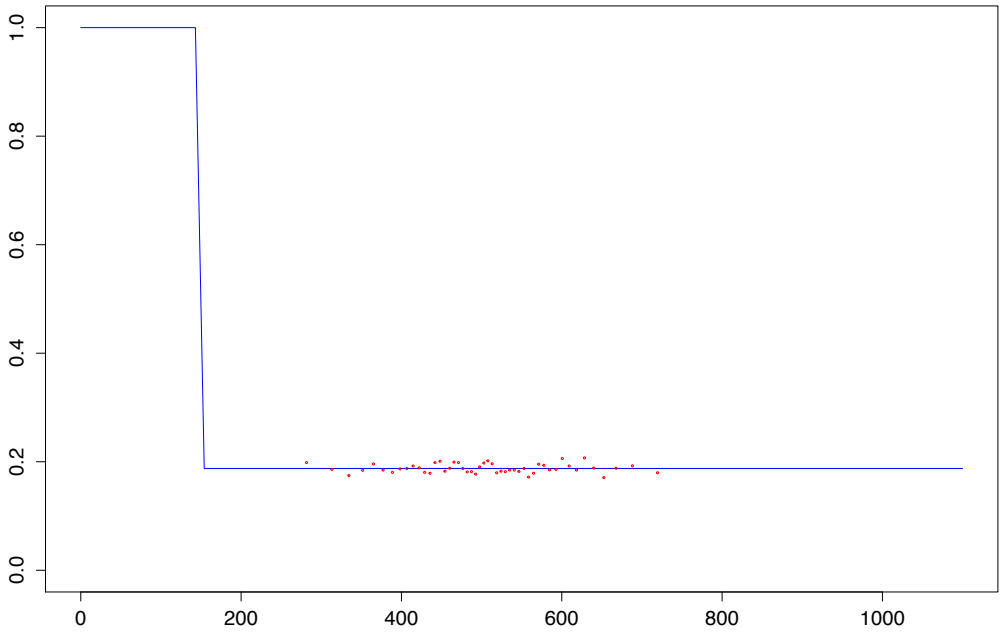

Observamos algo similar nos gráficos obtidos para as demais simulações: o gráfico é uma reta praticamente horizontal entre 200 e 800, intervalo no qual concentram-se os pontos gerados pelo método. E este tipo de gráfico pode ser obtido com praticamente qualquer valor de a.

7.1.3. *Máxima Verosimilhança.*

A tabela 7.4 resume os resultados obtidos pelo método da máxima verosimilhança. Mais uma vez observamos a dificuldade com questões com parâmetro b alto. Novamente, a questão 15 chama à atenção pelo grande desvio no parâmetro a. Não obstante esta grande variação, o método da máxima verosimilhança não gerou valores negativos de a.

Tabela 7.4. Estimativas (máxima verosimilhança)

Questão	a	média a	desvio a	b	média b	desvio b	c	média c	desvio c
1	0.0197	0.0218	0.0004	550.4	553.3	1.0	0.185	0.186	0.004
2	0.0238	0.0284	0.0030	836.7	840.0	5.2	0.216	0.217	0.002
3	0.022	0.0249	0.0007	654.4	656.9	1.3	0.251	0.252	0.003
4	0.0247	0.0291	0.0005	574.4	577.6	0.5	0.118	0.120	0.003
5	0.0371	0.0684	0.0032	287.5	289.0	1.1	0.104	0.099	0.015
6	0.0142	0.0149	0.0006	802.4	804.7	3.8	0.168	0.169	0.002
7	0.0374	0.0514	0.0012	705.6	706.9	1.0	0.113	0.112	0.001
8	0.0114	0.0118	0.0002	273.7	274.5	7.2	0.141	0.133	0.048
9	0.0103	0.0105	0.0001	275.8	277.9	3.0	0.142	0.140	0.022
10	0.0152	0.0157	0.0002	242.9	242.3	2.1	0.182	0.187	0.018
11	0.0107	0.0113	0.0005	717.6	718.2	2.5	0.17	0.172	0.005
12	0.0109	0.0111	0.0002	214.1	215.3	1.3	0.226	0.228	0.025
13	0.0121	0.0124	0.0003	532.7	534.7	1.9	0.162	0.159	0.007
14	0.025	0.0276	0.0011	738	741.9	2.1	0.237	0.236	0.002
15	0.0448	1.0668	2.4001	963	959.8	7.3	0.187	0.187	0.001
16	0.0378	0.0558	0.0012	517.7	520.0	0.4	0.17	0.167	0.003
17	0.0078	0.0078	0.0002	354.4	353.1	8.7	0.188	0.177	0.028
18	0.0122	0.0125	0.0002	250.4	250.6	3.1	0.168	0.169	0.021
19	0.0043	0.0044	0.0001	457.5	465.8	0.3	0.231	0.240	0.003
20	0.0203	0.0221	0.0005	281.2	278.7	3.2	0.266	0.239	0.022
21	0.0241	0.0276	0.0031	838.9	844.4	7.2	0.154	0.154	0.001
22	0.0182	0.0193	0.0003	442.1	442.2	2.0	0.254	0.239	0.009
23	0.0251	0.0298	0.0005	545.4	548.7	0.9	0.218	0.220	0.003
24	0.0367	0.0691	0.0087	812	811.5	2.8	0.136	0.136	0.001
25	0.019	0.0230	0.0091	986.7	984.9	7.1	0.178	0.178	0.002
26	0.0196	0.0223	0.0025	927.1	929.1	9.4	0.094	0.094	0.001
27	0.0212	0.0233	0.0006	678	680.4	1.2	0.205	0.204	0.002
28	0.0013	0.0021	0.0021	912.6	910.7	5.4	0.239	0.263	0.088
29	0.0411	0.0660	0.0013	396.3	393.3	0.4	0.278	0.217	0.004
30	0.037	0.0512	0.0009	476.2	477.3	0.5	0.225	0.212	0.004
31	0.0211	0.0238	0.0006	649.2	651.7	1.0	0.161	0.162	0.002
32	0.0286	0.0332	0.0011	224.7	218.6	4.1	0.183	0.152	0.037
33	0.0257	0.0310	0.0004	602	604.9	0.6	0.166	0.168	0.003
34	0.0318	0.0399	0.0006	456.5	457.9	0.7	0.213	0.199	0.004
35	0.012	0.0125	0.0003	621.8	624.8	1.4	0.147	0.148	0.005
36	0.0008	0.0008	0.0002	613.7	657.3	15.5	0.294	0.307	0.011
37	0.0144	0.0156	0.0009	948	947.4	3.3	0.108	0.108	0.001
38	0.0014	0.0014	0.0002	825.4	825.7	1.0	0.18	0.179	0.023
39	0.0196	0.0208	0.0005	220.1	218.1	7.4	0.255	0.270	0.063
40	0.0205	0.0243	0.0038	928.9	931.6	10.7	0.102	0.102	0.001
41	0.0344	0.0452	0.0007	431.2	431.9	0.6	0.238	0.215	0.004
42	0.0274	0.0335	0.0009	663.8	665.5	0.9	0.215	0.215	0.002
43	0.0332	0.0438	0.0015	683.5	684.4	0.8	0.146	0.145	0.001
44	0.0188	0.0199	0.0006	203.7	202.0	4.7	0.339	0.351	0.042
45	0.0231	0.0267	0.0004	559	562.0	0.9	0.223	0.224	0.004

Vejamos os gráficos correspondentes para duas simulações diferentes:

Simulação 1, $a = 0.0186, b = 963.0, c = 0.186$

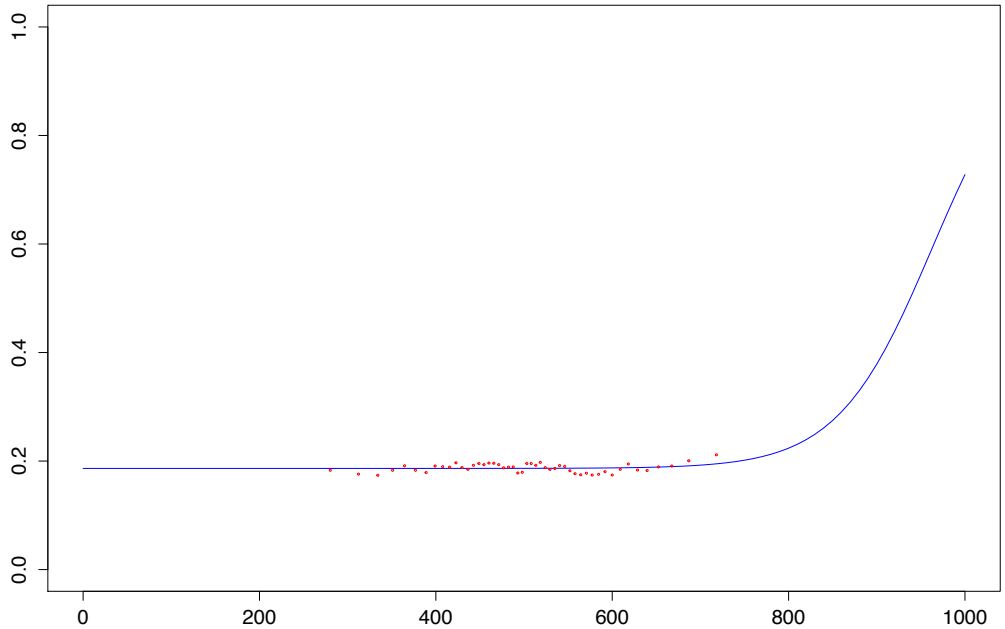

Simulação 9, $a = 10.9, b = 954.4, c = 0.187$

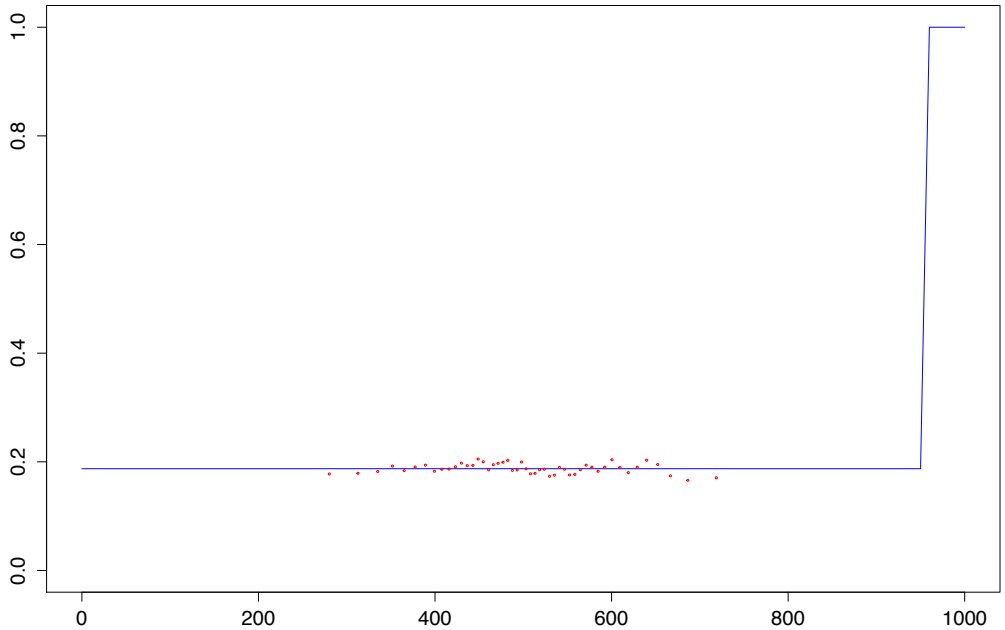

A seguir comparamos os resultados dos três métodos de maneira mais precisa.

7.1.4. *Comparação dos Resultados.* Utilizamos a norma euclidiana para comparar os resultados das estimações dos parâmetros obtidas com os três métodos. Mais precisamente, para cada método, cada questão e cada parâmetro, sendo p o valor teórico do parâmetro e $p_1, p_2, \ldots, p_{25}$ os valores estimados com os dados de cada uma das simulações, calculamos $N = \sum_{k=1}^{25}(p - p_k)^2$. Para cada questão e cada parâmetro, observamos qual dos três métodos tem o menor valor de N e admitimos que este tenha sido o método mais bem sucedido. Os resultados estão compilados na tabela 7.5, na qual, por simplicidade, utilizamos o número 1 para o método "pacote ltm", o número 2 para o método "dos intervalos" e o número 3 para o método da "máxima verosimilhança".

Observamos que o pacote ltm, mesmo sem utilizar a informação sobre a nota atribuída a cada candidato, é o que mais bem estima os parâmetros, particularmente o parâmetro a. Já o método dos intervalos foi o menos preciso.

Contudo, os parâmetros obtidos na maioria das questões foram muito próximos aos teóricos em todos os métodos. Maior desvio observou-se em questões com parâmetro b muito alto.

8. Conclusões

A partir dos microdados do ENEM, estimamos os parâmetros de cada questão da prova de Matemática de 2012 por três métodos diferentes. Os resultados obtidos foram compatíveis e a partir deles fomos capazes de reproduzir satisfatoriamente as notas dos candidatos através do método de máxima verosimilhança.

O método dos intervalos tem vantagens na simplicidade e velocidade dos cálculos, mas é menos preciso. Acreditamos que seu maior mérito seja proporcionar uma ferramenta de visualização de dados que permite rapidamente identificar questões com comportamento adequado ou inadequado ao modelo, e também posteriormente avaliar a adequação dos parâmetros estimados, permitindo-nos refinar os cálculos quando necessário.

Os parâmetros obtidos pelo método da máxima verosimilhança foi o mais eficiente ao reproduzir as notas do ENEM, especialmente para notas menores. Para notas acima da média, os parâmetros obtidos pelos três métodos levam a resultados mais próximos.

A utilização do pacote ltm com posterior ajuste de escala através da média e desvio padrão da distribuição notas na população gerou os melhores resultados

Tabela 7.5. Comparação entre os três métodos

Questão	a	b	c
1	1	1	3
2	1	3	2
3	1	1	3
4	1	1	1
5	1	3	3
6	1	2	3
7	1	3	1
8	1	3	3
9	1	1	3
10	1	3	3
11	1	3	1
12	1	3	3
13	1	1	3
14	1	1	1
15	1	3	3
16	1	1	2
17	1	3	3
18	1	3	3
19	3	3	3
20	1	3	3
21	1	3	3
22	1	3	1
23	1	1	1
24	1	3	3
25	1	3	3
26	1	3	3
27	1	1	3
28	1	3	3
29	1	3	1
30	1	1	1
31	1	1	3
32	1	3	3
33	1	1	1
34	1	1	1
35	1	1	3
36	1	3	3
37	3	3	3
38	1	3	3
39	1	3	3
40	1	3	3
41	1	3	1
42	1	1	1
43	1	3	1
44	1	3	3
45	1	1	3

na estimação dos parâmetros das simulações, apesar de subutilizar a informação disponível (não leva em conta a nota atribuída a cada padrão de resposta).

9. Próximos Passos

9.1. **Otimização da função global dos parâmetros.** Uma ideia para melhorar ainda mais a estimativa dos parâmetros das questões do ENEM é utilizar todas as questões simultaneamente, ao invés de separadamente como nos métodos dos intervalos e da máxima verosimilhança, mas levando em conta as notas, a diferença do que fizemos ao utilizar o pacote ltm. Assim, o problema consistiria em otimizar uma função de $45 \times 3 = 135$ parâmetros.

9.2. **Estimação conjunta e métodos Bayesianos.** Para suavizar as distorções obtidas no cálculo de notas (proficiências) muito baixas ou muito altas podem ser utilizados métodos Bayesianos nas estimativas, assim como procedimentos de estimação conjunta para itens e proficiências.

9.3. **Simulados.** Para avaliar futuros candidatos ao ENEM, podem ser elaborados simulados consistindo de uma mescla entre questões anteriores do ENEM, cujos parâmetros podem ser estimados por um dos métodos aqui descritos, e novas questões cujos parâmetros seriam determinados posteriormente. Algumas perguntas pertinentes envolvem as quantidades adequadas de questões conhecidas e questões novas, assim como de candidatos para tornar aceitável a estimação de parâmetros, e também os intervalos de confiança relativos aos parâmetros e às proficiências calculadas.

Outra ideia relevante a ser explorada é a da possível elaboração de simulados *adaptativos* para estimar a proficiência de futuros candidatos na mesma escala do ENEM. Neste tipo de simulados, realizados por computador, uma nova questão é selecionada para o candidato em função das respostas dadas por ele às anteriores questões já propostas. A expectativa é de que sejam necessárias bem menos de 45 questões para estimar a proficiência com intervalo de confiança satisfatório.

9.4. **Mais informação sobre o ML3 utilizado no ENEM.** Finalmente, acreditamos ser de interesse uma análise sobre a adequação dos dados ao modelo ML3 no ENEM, como descrito, por exemplo, em [7] ou [6], assim como o cálculo dos intervalos de confiança para as notas.

Referências

[1] *Item Response Theory: Parameter Estimation Techniques, Second Edition (Statistics: A Series of Textbooks and Monographs)*. CRC Press, 2004.

[2] Dalton F. Andrade and Camila A. Karino. Nota técnica: Teoria de resposta ao item. *Ministério da Educação - INEP - Diretoria de Avaliação da Educação Básica (DAEB)*, 2011. `http://download.inep.gov.br/educacao_basica/enem/nota_tecnica/2011/nota_tecnica_tri_enem_18012012.pdf`.

[3] Dalton F. Andrade, Heliton R. Tavares, and Raquel C. Valle. Teoria da resposta ao item: Conceitos e aplicações. *SINAPE*, 2000. `http://www.ufpa.br/heliton/arquivos/LivroTRI.pdf`.

[4] Assessoria de Comunicação Social. Nota de imprensa: Pré-testes seguem o rigor de segurança dos demais exames. *Ministério da Educação*, 2011. `http://portal.mec.gov.br/component/tags/tag/35239-pre-teste`.

[5] Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira INEP. Matriz de referência enem. *Ministério da Educação*, 2012. `http://download.inep.gov.br/educacao_basica/enem/downloads/2012/matriz_referencia_enem.pdf`.

[6] R.K. Hambleton, H. Swaminathan, and H.J. Rogers. *Fundamentals of Item Response Theory*. Measurement Methods for the So. SAGE Publications, 1991.

[7] R. Klein. Alguns aspectos da teoria da resposta ao item relativos à estimação das proficiências. *SIAM J. Optim.Ensaio: Avaliação e Políticas Públicas em Educação, Rio de Janeiro*, 21 n. 78:35–56, 2013.

[8] R Core Team. *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria, 2015. `https://www.R-project.org/`.

[9] Dimitris Rizopoulos. ltm: An R package for latent variable modelling and item response theory analyses. *Journal of Statistical Software*, 17(5):1–25, 2006. `http://www.jstatsoft.org/v17/i05/`.

[10] Dimitris Rizopoulos. *Latent Trait Models under IRT*, 2015. `https://cran.r-project.org/web/packages/ltm/ltm.pdf`.

[11] Guido Rossum. Python reference manual. Technical report, Amsterdam, The Netherlands, 1995. `https://www.python.org/`.